ΔΕΙΓΜΑΤΙΚΕΣ ΚΑΤΑΝΟΜΕΣ

Στατιστικές Μέθοδοι στην Επιστήμη Δεδομένων, Κ. Πετρόπουλος

Π.Μ.Σ. «MCDA», Δ.Π.Μ.Σ. «ΥΔΑ»

Μπορούν να χρησιμοποιηθούν τα δεδομένα για την εξαγωγή χρήσιμων πληροφοριών για την κατανομή του πληθυσμού;
Έστω $X_1, X_2, \ldots, X_n$ τ.μ. και x_i είναι η πραγματοποίηση (τιμή) κάθε παρατήρησης (μεταβλητής) X_i, $i = 1, 2, \ldots, n$.

Τυχαία Μεταβλητή

$$X_i : \Im \to \mathbb{R}$$

Αν $\forall B \in \mathcal{B}$, $X_i^{-1}(B) \in \Im$, τότε X_i είναι μετρήσιμη συνάρτηση και ονομάζεται τυχαία μεταβλητή.

Ποια είναι η κατανομή του $\bar{X}$;

$$\text{Πληθυσμός (N)} \rightarrow \text{Δείγμα } (n)$$

Έστω ότι ο πληθυσμός αποτελείται από $N = 8$ άτομα, τότε

$$\mu = \frac{\sum_{i=1}^{N} x_i}{N} \text{ και } \sigma^2 = \frac{\sum_{i=1}^{N} (x_i - \mu)^2}{N}$$

και θέλω να πάρω ένα δείγμα μεγέθους $n = 4$ άτομα.

Η δειγματοληψία μπορεί να γίνει είτε με επανάθεση
($8^4 = 4096$ διαφορετικά δείγματα),
είτε χωρίς επανάθεση ($\binom{8}{4} = 70$ διαφορετικά δείγματα)

Ποια είναι η κατανομή του $\bar{X}$;

$$Var\bar{X} = \frac{\sigma^2}{n}\left(\frac{N-n}{N-1}\right)$$

$$Var\bar{X} = Var\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2} Var\left(\sum_{i=1}^{n} X_i\right) =$$

$$\frac{1}{n^2}\left[\sum_{i=1}^{n} VarX_i + 2\sum_{i<j} Cov(X_i, X_j)\right] =$$

$$\frac{1}{n^2}\left[n\sigma^2 + 2\sum_{i<j} Cov(X_i, X_j)\right].$$

$$Cov(X_i, X_j) = E(X_i X_j) - E(X_i)E(X_j) = E(X_i X_j) - \mu^2.$$

$$E(X_i X_j) = \sum_i \sum_j x_i x_j P(X_i = x_i, X_j = x_j) = \frac{\sum_i \sum_j x_i x_j}{N(N-1)}$$

$$P(X_i = x_i, X_j = x_j) = P(X_i = x_i | X_j = x_j) P(X_j = x_j) = \frac{1}{N-1}\,\frac{1}{N}$$

Ποια είναι η κατανομή του $\bar{X}$;

Όμως,

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i-\mu)^2 = \frac{1}{N}\sum_{i=1}^{N}\left(x_i - \frac{1}{N}\sum_{i=1}^{N}x_i\right)^2 =$$

$$\frac{1}{N}\sum_{i=1}^{N}x_i^2 - \left(\frac{1}{N}\sum_{i=1}^{N}x_i\right)^2 = \frac{1}{N}\sum_{i=1}^{N}x_i - \frac{1}{N^2}\left(\sum_{i=1}^{N}x_i^2 + \sum_{i=1}^{N}\sum_{j=1}^{N}x_i x_j\right)$$

$$\Rightarrow \sigma^2 = \sum_{i=1}^{N}x_i^2\left(\frac{1}{N}-\frac{1}{N^2}\right) - \frac{1}{N^2}\sum_{i=1}^{N}\sum_{j=1}^{N}x_i x_j$$

$$\Rightarrow \sum_{i=1}^{N}\sum_{j=1}^{N}x_i x_j = (N-1)\sum_{i=1}^{N}x_i^2 - N^2\sigma^2.$$

Επομένως,

$$E(X_iX_j) = \frac{\sum_i\sum_j x_i x_j}{N(N-1)} = \frac{1}{N}\sum_{i=1}^{N}x_i^2 - \frac{N}{N-1}\sigma^2.$$

Ποια είναι η κατανομή του $\bar{X}$;

Τελικά,

$$Cov(X_i, X_j) = E(X_i X_j) - \mu^2 = \frac{1}{N}\sum_{i=1}^{N} x_i^2 - \frac{N}{N-1}\sigma^2 - \mu^2. \qquad (1)$$

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N} x_i^2 - \mu^2 \Rightarrow \frac{1}{N}\sum_{i=1}^{N} x_i^2 = \mu^2 + \sigma^2 \qquad (2)$$

Από 1 και 2 προκύπτει ότι,

$$Cov(X_i, X_j) = \mu^2 + \sigma^2 - \frac{N}{N-1}\sigma^2 - \mu^2 = -\frac{\sigma^2}{N-1}$$

Άρα,

$$Var\bar{X} = \frac{1}{n^2}\left[n\sigma^2 + 2\sum_{i<j} Cov(X_i, X_j)\right] = \frac{\sigma^2}{n} + \frac{2}{n^2}\left(\frac{n(n-1)}{2}\right)\left(-\frac{\sigma^2}{N-1}\right) = \frac{\sigma^2}{n}\left(\frac{N-n}{N-1}\right)$$

Ποια είναι η κατανομή του $\bar{X}$;

Αφού, λοιπόν, έχω την δυνατότητα να πάρω πολλά δείγματα μεγέθους n, καθ' ένα από αυτά θα έχει και τον δικό του μέσο $\bar{X}_i$,

$$E\bar{X}_i = \mu \quad \text{και} \quad Var\bar{X}_i = \frac{\sigma^2}{n} \left(\frac{N-n}{N-1} \right).$$

Για κάθε ένα από αυτά τα δείγματα έχω κάποιο σφάλμα στην εκτίμηση του μ,

$$\begin{aligned} \varepsilon_1 &= \bar{x}_1 - \mu \\ \varepsilon_2 &= \bar{x}_2 - \mu \\ &\vdots \\ \varepsilon_k &= \bar{x}_k - \mu \end{aligned}$$

Αν $\mathcal{E}$ είναι η τ.μ. με τιμές $\varepsilon_1, \varepsilon_2, \ldots, \varepsilon_k$, τότε $\bar{X} - \mu = \mathcal{E}$, όπου

$$E\mathcal{E} = 0 \quad \text{και} \quad Var\mathcal{E} = Var\bar{X}.$$

Ποια είναι η κατανομή του $\bar{X}$;

Οπότε, αν παράγω το δείγμα πολλές φορές (με επανάθεση) και φτιάξω το ιστόγραμμα, κρατάω κάθε φορά αυτό που με ενδιαφέρει.

Αν, επομένως, βρω ότι τα δεδομένα μου ακολουθούν κατανομή Γάμμα $G(a, b)$, πρέπει να εκτιμήσω αυτές τις παραμέτρους από το δείγμα, άρα η κατανομή μου είναι η $G(\hat{a}, \hat{b})$
(Εκτίμηση μέγιστης πιθανοφάνειας ή ροπομεθόδου.)

Παραγωγή τυχαίων αριθμών

Πρόταση 1

Αν X είναι συνεχής τ.μ., με συνάρτηση κατανομής F, τότε η τ.μ. $Y = F(X) \sim \mathcal{U}(0,1)$.

Απόδειξη: Έστω F_Y η συνάρτηση κατανομής της τ.μ. Y,
$F_Y(y) = P(Y \leqslant y) = P(F(X) \leqslant y) = P(X \leqslant F^{-1}(y)) = F(F^{-1}(y)) = y.$
Επομένως, $f_Y(y) = \dfrac{d}{dy}(F_Y(y)) = 1$, $0 < y < 1$, δηλαδή $Y \sim \mathcal{U}(0,1)$.

Πρόταση 2

Αν X είναι συνεχής τ.μ., με συνάρτηση κατανομής F και η τ.μ. $U \sim \mathcal{U}(0,1)$, τότε η τ.μ. $Y = F^{-1}(U) \sim F$.

Απόδειξη: Έστω F_Y η συνάρτηση κατανομής της τ.μ. Y,
$F_Y(y) = P(F^{-1}(U) \leqslant y) = P(U \leqslant F(y)) = F(y),$
αφού η τ.μ. $U \sim \mathcal{U}(0,1)$ και $P(U \leqslant u) = u$.

Παρατήρηση

Αν μπορούμε να παράγουμε τιμές από την $\mathcal{U}(0,1)$, μπορούμε να παράγουμε από οποιαδήποτε συνεχή κατανομή.

Μέθοδος Box-Muller

Άσκηση 1

Αν $U \sim \mathcal{U}(0,1)$, τότε η τ.μ. $\Theta = 2\pi U \sim \mathcal{U}(0, 2\pi)$.

Άσκηση 2

Αν $U \sim \mathcal{U}(0,1)$, τότε η τ.μ. $X = -2 \ln U \sim \mathcal{E}(2)$.

Άσκηση 3

$$\left.\begin{array}{l} \Theta \sim \mathcal{U}(0, 2\pi) \\ R^2 \sim \mathcal{E}(2) \end{array}\right\} \Rightarrow \begin{array}{l} N_1 = R\cos\Theta \sim \mathcal{N}(0,1) \\ N_2 = R\sin\Theta \sim \mathcal{N}(0,1) \end{array}$$

Μέθοδος Box-Muller

Με αυτήν την μέθοδο, γνωρίζοντας τις τιμές δύο ομοιόμορφων, μπορώ να παράγω δύο τιμές από την τυπική κανονική κατανομή $\mathcal{N}(0,1)$.

$$\left.\begin{array}{l} U_1 \sim \mathcal{U}(0,1) \\ U_2 \sim \mathcal{U}(0,1) \end{array}\right\} \Rightarrow \begin{array}{l} N_1 = (-2\ln U_1)^{1/2}\cos(2\pi U_2) \sim \mathcal{N}(0,1) \\ N_2 = (-2\ln U_1)^{1/2}\sin(2\pi U_2) \sim \mathcal{N}(0,1) \end{array}$$

Αλγόριθμος

B1 Παραγωγή τυχαίων αριθμών U_1 και U_2

B2 Θέτω $R^2 = -2\ln U_1$, $\Theta = 2\pi U_2$

B3 Θέτω $X_1 = \sqrt{-2\ln U_1}\cos(2\pi U_2)$, $X_2 = \sqrt{-2\ln U_1}\sin(2\pi U_2)$

Παρατήρηση

Αν θέλω να παράγω τυχαίες μεταβλητές από $N(\mu, \sigma^2)$, θέτω $Y_1 = \mu + \sigma X_1$, $Y_2 = \mu + \sigma X_2$