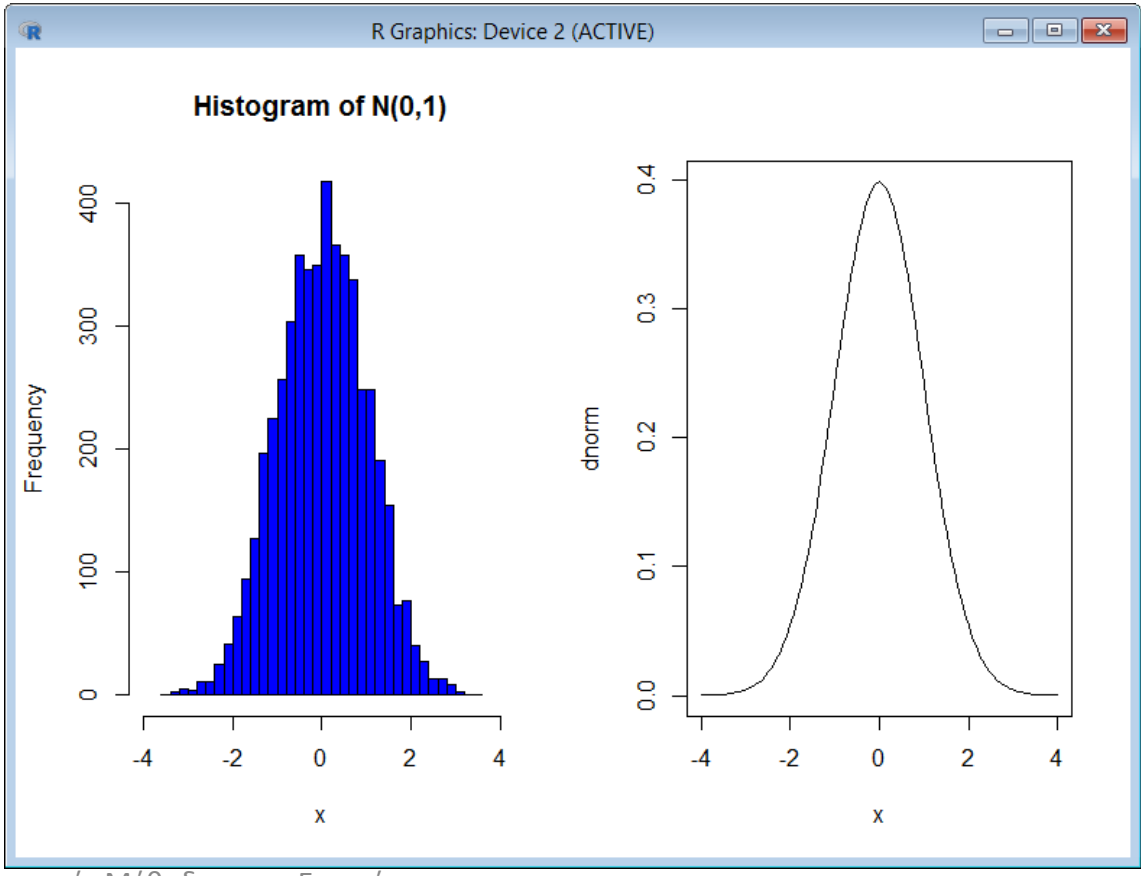
Θέματα Στατιστικής στη γλώσσα R

- Παραγωγή τυχαίων δειγμάτων
- Μετασχηματισμοί τυχαίων μεταβλητών
- Ο ασθενής νόμος των μεγάλων αριθμών
- Το κεντρικό οριακό θεώρημα

Παραγωγή τυχαίων δειγμάτων

```
> par(mfrow=c(1,2))
> z<-rnorm(5000) # tuxaio deigma mege8ous 5000 apo N(0,1)
> hist(z,nclass=25,col=4,xlab="x",main="Histogram of N(0,1)$
Waiting to confirm page change...
> plot(dnorm,xlim=c(-4,4))
> par(mfrow=c(1,1))
>
> mean(z)
[1] 0.01848778
> sd(z)
[1] 1.002524
```



Παραγωγή τυχαίων δειγμάτων

από κανονική κατανομή ή άλλες γνωστές κατανομές

Description

Density, distribution function, quantile function and random generation for the normal distribution with mean equal to mean and standard deviation equal to sd.

Usage

```
dnorm(x, mean = 0, sd = 1, log = FALSE)
pnorm(q, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
qnorm(p, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
rnorm(n, mean = 0, sd = 1)
```

Arguments

x, q	vector of quantiles.
p	vector of probabilities.
n	number of observations.
mean	vector of means.
sd	vector of standard deviations.
log, log.p	logical; if TRUE, probabilities p are given as log(p).
lower.tail	logical; if TRUE (default), probabilities are $P[X \leq x]$ otherwise, $P[X > x]$

Παραγωγή τυχαίων δειγμάτων

Distributions {stats} R Documentation

Distributions in the stats package

Description

Density, cumulative distribution function, quantile function and random variate generation for many standard probability distributions are available in the **stats** package.

Details

The functions for the density/mass function, cumulative distribution function, quantile function and random variate generation are named in the form `dxxx`, `pxxx`, `qxxx` and `rxxx` respectively.

For the beta distribution see `dbeta`.

For the binomial (including Bernoulli) distribution see `dbinom`.

For the Cauchy distribution see `dcauchy`.

For the chi-squared distribution see `dchisq`.

For the exponential distribution see `dexp`.

For the F distribution see `df`.

For the gamma distribution see `dgamma`.

For the geometric distribution see `dgeom`. (This is also a special case of the negative binomial.)

For the hypergeometric distribution see `dhyper`.

For the log-normal distribution see `dlnorm`.

For the multinomial distribution see `dmultinom`.

For the negative binomial distribution see `dnbinom`.

For the normal distribution see `dnorm`.

For the Poisson distribution see `dpois`.

For the Student's t distribution see `dt`.

For the uniform distribution see `dunif`.

For the Weibull distribution see `dweibull`.

For less common distributions of test statistics see `pbirthday`, `dsignrank`, `ptukey` and `dwilcox` (and see the 'See Also' section of `cor.test`).

See Also

`RNG` about random number generation in **R**.

The CRAN task view on distributions, https://cran.r-project.org/web/views/Distributions.html, mentioning several CRAN packages

Υλικό για εξάσκηση

Να πάρετε τ.δ. $\underset{\sim}{U}=(U_1,\ldots,U_n)$ από $U(0,1)$ $(n=10, 100, 1000)$

α. να υπολογιστούν για το δείγμα, η μέση τιμή, η διασπορά και η διάμεσος. Να συμφωνούν με τις θεωρητικές τιμές τους.

β. να γίνει το ιστόγραμμα συχνοτήτων.

γ. να γίνει ο μετασχηματισμός $X_i = -2U_i + 1$ $i=1,\ldots,n$

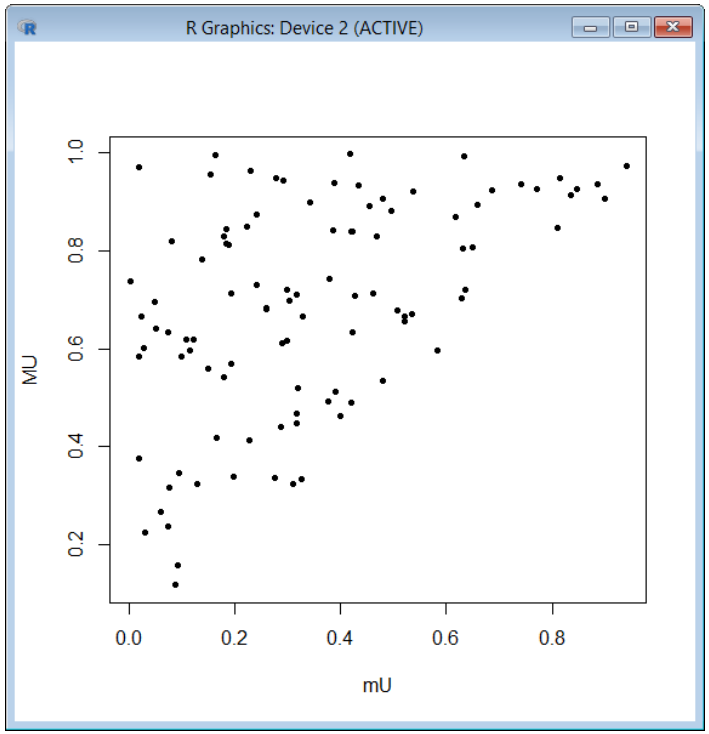
Για το δείγμα $\underset{\sim}{X}$ να απαντηθούν τα ερωτήματα α., β.

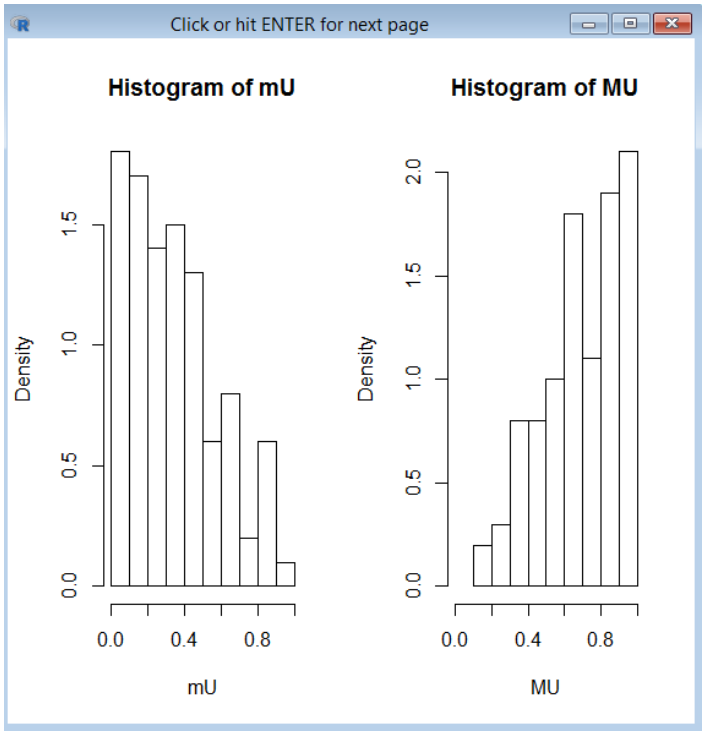
Από ποια κατανομή προέρχονται τα X_i ;

Παραγωγή τυχαίων δειγμάτων

Έστω ότι έχω τ.δ. από U(0,1).
Με ενδιαφέρει η κατανομή
της $X_{(1)}$ και της $X_{(n)}$
καθώς και η δομή συσχέτισής τους

```
> a<-mM1.unif(2,100)
Waiting to confirm page change..
Waiting to confirm page change..
0.3432301 0.05577739
0.6856588 0.04803862
[1] 0.0258796
 > a
NULL
```



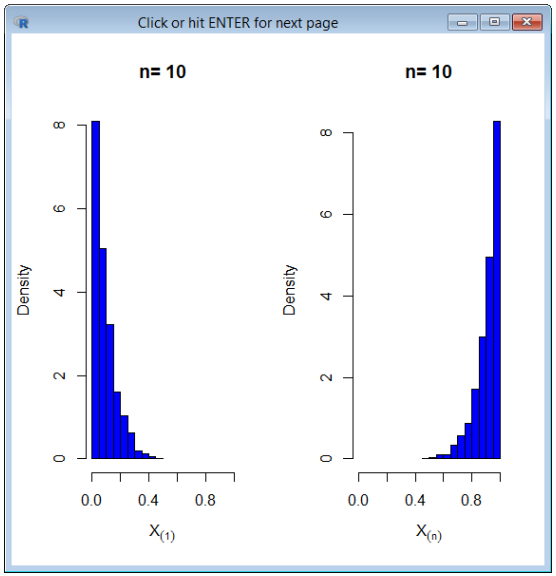


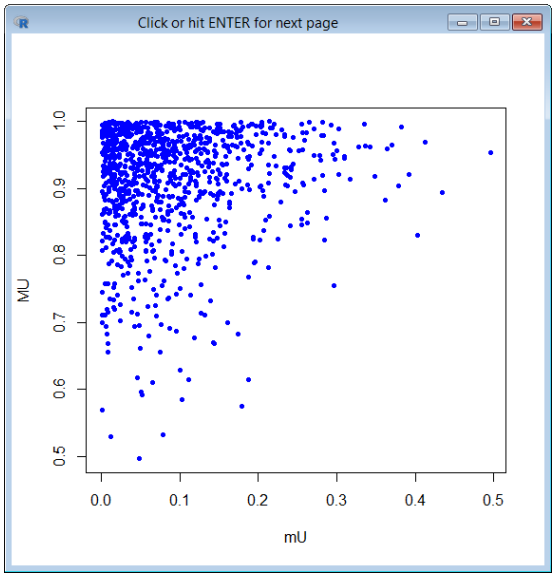
Παραγωγή τυχαίων δειγμάτων

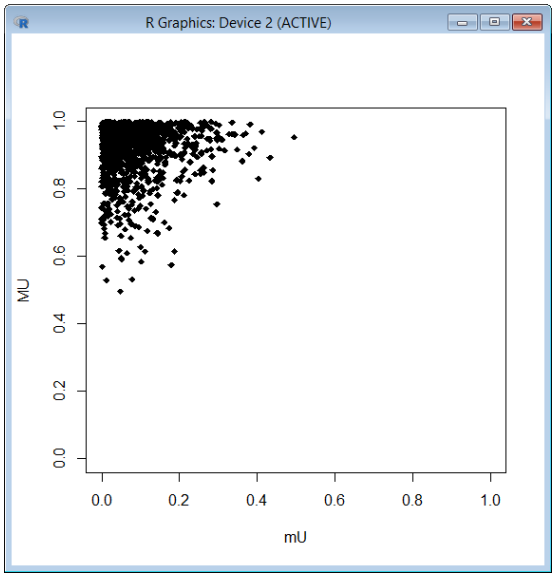
```
> mM1.unif<-function(n,M){    # n:sample size  M:simulation steps
+ mU<-numeric(M)
+ MU<-numeric(M)
+ for (k in 1:M){
+ U<-runif(n)
+ U<-sort(U)
+ mU[k]<-U[1]
+ MU[k]<-U[n]
+ }
+ par(mfrow=c(1,2))
+ hist(mU,probability=TRUE,xlim=c(0,1))
+ hist(MU,probability=TRUE,xlim=c(0,1))
+ par(mfrow=c(1,1))
+ plot(mU,MU,pch=20)
+ # oi deigmatikes times tou mesou kai tns diasporas tou X_(1)
+ cat(c(mean(mU),var(mU)),"\n")
+ # oi deigmatikes times tou mesou kai tns diasporas tou X_(n)
+ cat(c(mean(MU),var(MU)),"\n")
+ # n deigmatikn timn tou cov(X(1),X(n))
+ print(cov(mU,MU))
+ # oloi oi upologismoi 8a xa8ouv
+      return()
+ }
```

Παραγωγή τυχαίων δειγμάτων

```
> plot(mM.unif(10,1000),pch=18,xlim=c(0,1),ylim=c(0,1))
Waiting to confirm page change...
Waiting to confirm page change...
E(X(1))= 0.09090909 var(X(1))= 0.006887052
0.08827723 0.006261708
E(X(n))= 0.9090909 var(X(n))= 0.006887052
0.91072 0.006921121
cov(X(1),X(n))= 0.0006887052
[1] 0.0006278964
Waiting to confirm page change...
```







Μετασχηματισμοί τ.μ.

ΠΡΟΤΑΣΗ:

Έστω συνεχής τ.μ. X με αθροιστική συνάρτηση κατανομής $F: \mathbb{R} \to [0,1]$. Τότε η τ.μ. $Y = F(X) \sim U(0,1)$

Απόδειξη:

$$P(Y \le y) = P(F(X) \le y) = \begin{cases} 0 & y < 0 \\ P(F^{-1}(F(X)) \le F^{-1}(y)) & 0 < y < 1 \\ 1 & y \ge 1 \end{cases}$$

εφόσον η F είναι επί του $(0,1)$ και γνησίως αύξουσα σε κάποιο ανοιχτό σύνολο $(\alpha, \beta) \subseteq \mathbb{R}$, $F: (\alpha, \beta) \to (0,1)$.

Οπότε υπάρχει η αντίστροφη συνάρτηση $F^{-1}: (0,1) \to (\alpha, \beta)$ και έχει την ίδια μονοτονία.

Οπότε $P(X \le F^{-1}(y)) = F(F^{-1}(y)) = y$ $\quad P(Y \le y) = \begin{cases} 0 & y < 0 \\ y & 0 < y < 1 \\ 1 & y \ge 1 \end{cases}$

Μετασχηματισμοί τ.μ.

ΠΡΟΤΑΣΗ (παραγωγή τ.δ. από συνεχή κατανομή με χρήση τ.δ από $U(0,1)$)

Εάν $U \sim U(0,1)$ και συνεχής κατανομή f με α.σ.κ $F: \mathbb{R} \to [0,1]$ τότε η τ.μ. $X = F^{-1}(U)$ ακολουθεί την κατανομή f.

Έτσι για να παράξουμε τ.δ. από την f αρκεί να έχουμε $u_1, \dots, u_n$ τ.δ. από $U(0,1)$

Ο μετασχηματισμός $X_i = F^{-1}(u_i)$ $i = 1, \dots, n$ μας δίνει $X_1, \dots, X_n$ τ.δ. από την f.

Υλικό για εξάσκηση

δ. Να γίνει ο μετασχηματισμός $Y_i = -\theta \ln(1-U_i)$ $i=1,\dots,n$
Για το δείγμα $\underset{\sim}{Y}$ να απαντηθούν τα ερωτήματα α., β.
Από ποια κατανομή προέρχονται τα Y_i;
(επιλέξτε διάφορες τιμές για την παράμετρο θ)

ε. Να πάρετε τ.δ. $\underset{\sim}{Z} = (Z_1, \dots, Z_n)$ από $N(0,1)$ $(n=100)$

- Να γίνει ο μετασχηματισμός $W_i = \Phi(Z_i)$ $i=1,\dots,n$
- Για το δείγμα $\underset{\sim}{W} = (W_1, \dots, W_n)$ να υπολογίσετε τη μέση τιμή, την τυπική απόκλιση και να κατασκευάσετε το ιστόγραμμα συχνοτήτων.

Υλικό για εξάσκηση

- Ποιο είναι το κάτω και το άνω 5% ποσοστιαίο σημείο του δείγματος;
  Ποιες είναι οι αντίστοιχες θεωρητικές τιμές τους;
- Ποια είναι τα $Z_{(5)}$, $Z_{(95)}$, $W_{(5)}$ και $W_{(95)}$ και τι σχέση έχουν μεταξύ τους;

Ο ασθενής νόμος των μεγάλων αριθμών

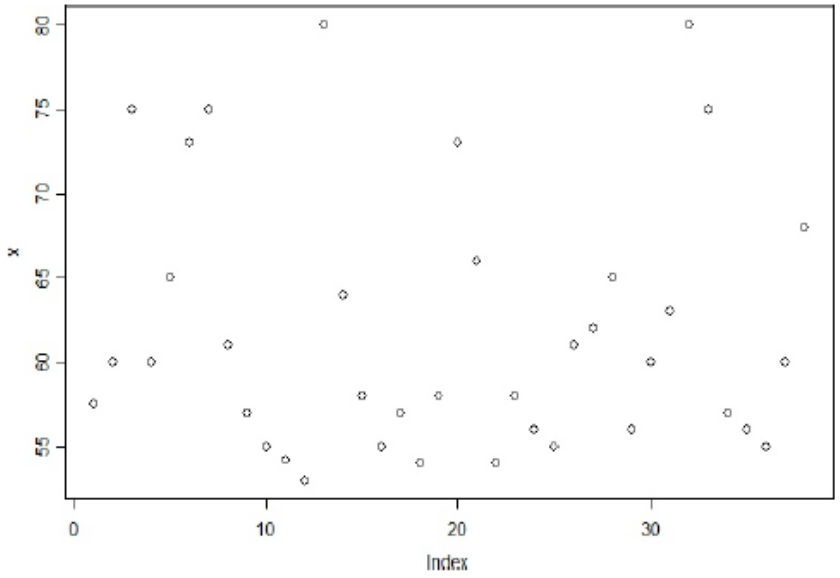
Έστω $X_1, X_2, \ldots, X_n$ ανεξάρτητες και ισόνομες τ.μ. με $E(X_1) = \mu < \infty$ τότε για τον δειγματικό μέσο ισχύει

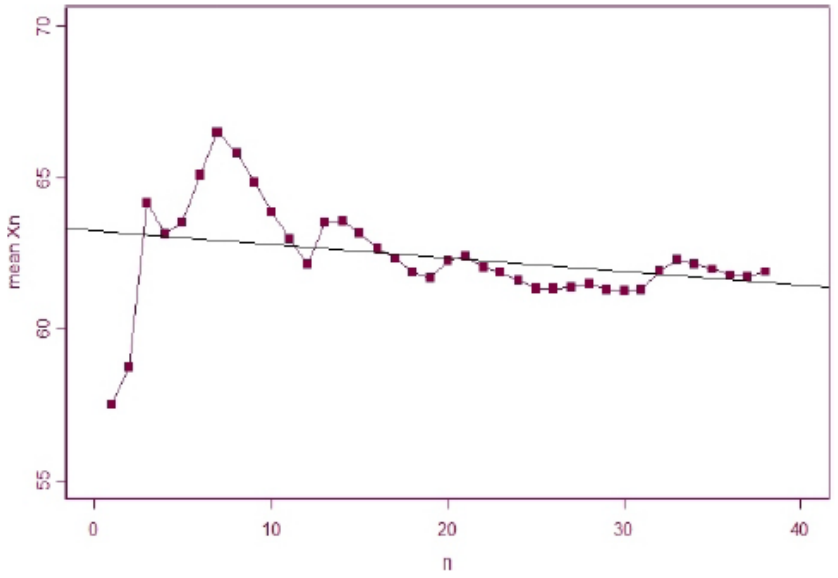
$$\overline{X_n} = \frac{X_1 + X_2 + \ldots + X_n}{n} \xrightarrow[n \to \infty]{\text{κατά πιθανότητα}} \mu$$

δηλαδή

$$\lim_{n \to \infty} P(|\overline{X}_n - \mu| \leq \varepsilon) = 1 \ \forall \varepsilon > 0$$

τυχαίο δείγμα μεγέθους $n = 38$ των βαρών των φοιτητών που παρακολούθησαν το μάθημα της Στατιστικής στις 7/10/2009



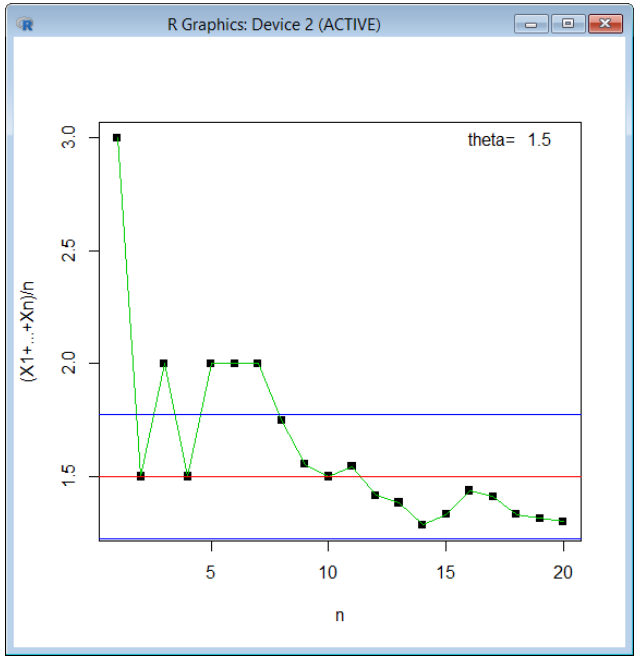


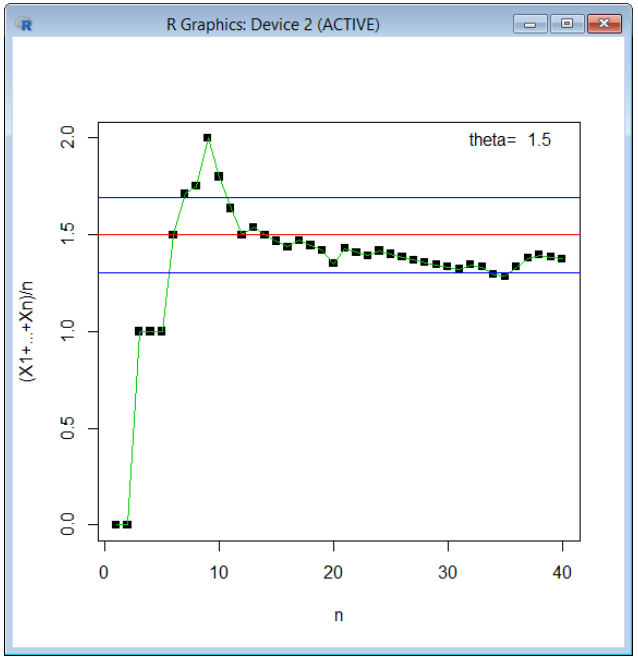
Κώδικας (για Poisson κατανομή)

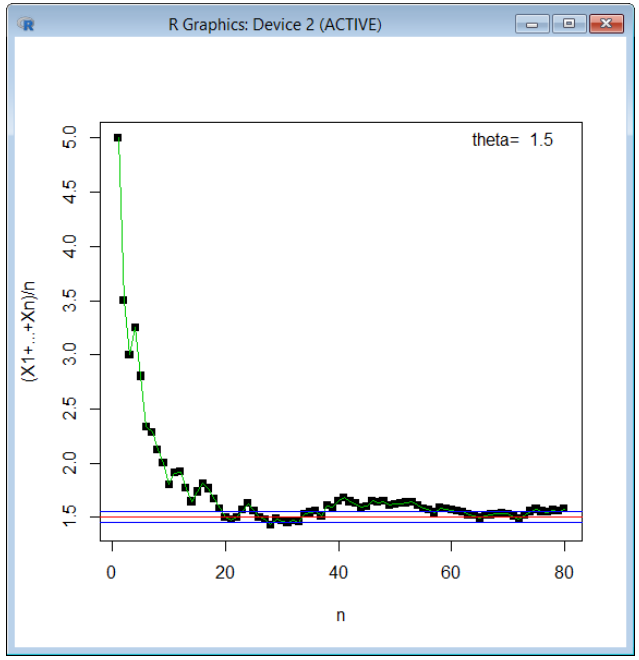
```
> WL.Pois<-function(N,th,e=sqrt(th/N)){
+  x<-rpois(N,th)
+  y<-rep(0,N)
+ for (n in 1:N) y[n]<-mean(x[1:n])
+
+ plot(y,xlab="n",ylab="(X1+...+Xn)/n",pch=15)
+ for (n in 2:N) lines(c(n-1,n),c(y[n-1],y[n]),type="l",col=3)
+
+ # avagrafetai n timn tns parametpou
+ text(N*0.85,max(y),"theta=")
+ text(N*0.95,max(y),th)
+
+ # n pragmatikn timn tou mesou
+ abline(a=th,b=0,col="red")
+ abline(a=th+e,b=0,col="blue")
+ abline(a=th-e,b=0,col="blue")
+ }
```

Κώδικας (για Poisson κατανομή)

```
> WL.Pois(20,1.5)
Waiting to confirm page change...
> WL.Pois(40,1.5)
Waiting to confirm page change...
> WL.Pois(80,1.5,0.05)
Waiting to confirm page change...
```







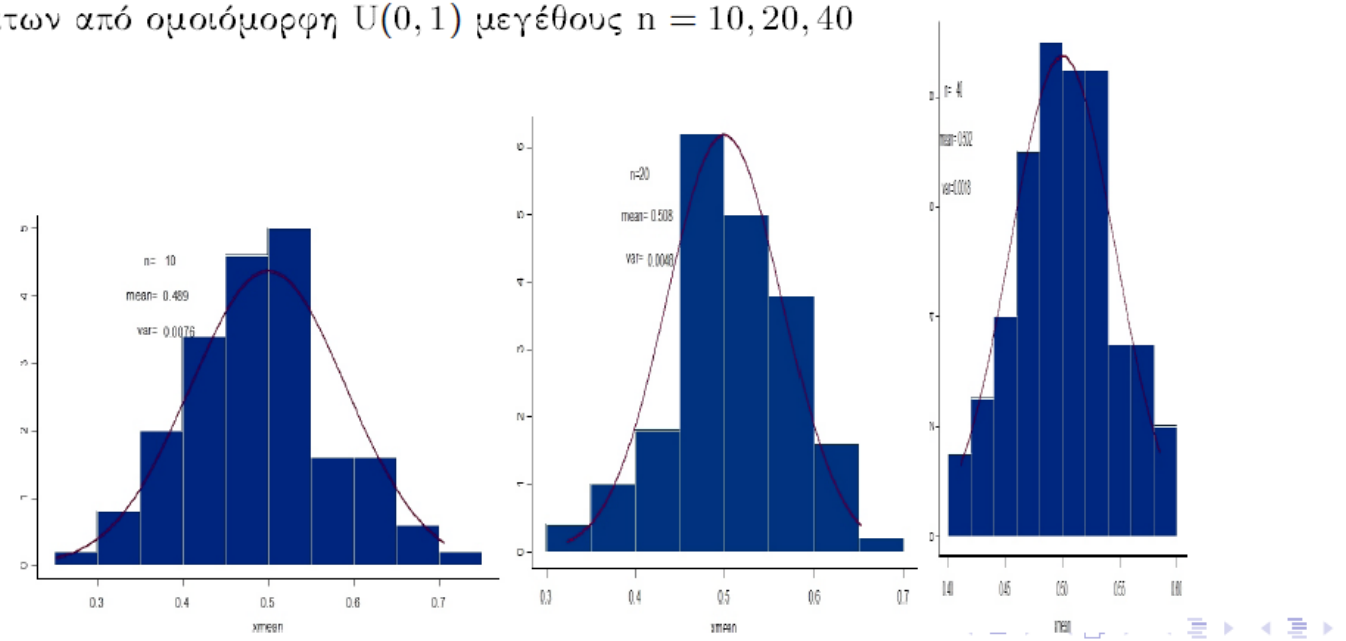
Το κεντρικό οριακό θεώρημα

Έστω $X_1, X_2, \ldots, X_n$ ανεξάρτητες και ισόνομες τ.μ. με $E(X_1) = \mu < \infty$ και $0 < Var(X_1) = \sigma^2 < \infty$ τότε για τον δειγματικό μέσο ισχύει

$$\overline{X_n} \xrightarrow[n\to\infty]{\text{κατά κατανομή}} N(\mu, \frac{\sigma^2}{n}) \qquad \text{ή} \qquad \frac{\overline{X_n} - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow[n\to\infty]{\text{κ. κ.}} N(0,1)$$

δηλαδή $$\lim_{n\to\infty} P\left(\frac{\sqrt{n}(\overline{X_n} - \mu)}{\sigma} \le x\right) = \Phi(x) \ \forall x \in \mathbb{R}$$

ιστογράμματα σχετικών συχνοτήτων (100 παρατηρήσεων) των μέσων τιμών τυχαίων δειγμάτων από ομοιόμορφη $U(0,1)$ μεγέθους $n = 10, 20, 40$



Κώδικας (για Poisson κατανομή)

```
> CLT.Pois<-function(n,th){
+ M<-1000
+ y<-rep(0,M)
+ for (k in 1:M) {
+ x<-rpois(n,th)
+ y[k]<-mean(x)
+ }
+
+ # oi 8ewpitikes times tou mesou kai tns diasporas tou bar(X)
+ # kai oi deigmatikes times
+ mXbar<-th
+ varXbar<-th/n
+ cat("E(bar(X))=",mXbar,"var(bar(X))=",varXbar,"\n")
+ cat(c(mean(y),var(y)),"\n")
+
+ hist(y,nclass=20,
+ xlab=expression(bar('X'[n])),
+      #expression(frac('X'[1]+ldots+'X'[n],n))),
+ main=paste("n=",n,", th=",th),probability = T,col="blue")
+ curve(dnorm(x,mean=mXbar,sd=sqrt(varXbar)),lwd=3,col="red",
+ add=T,xlim=c(mXbar-3*sqrt(varXbar),mXbar+3*sqrt(varXbar)))
+ }
```

Κώδικας (για Poisson κατανομή)

```
> CLT.Pois(5,1.4)
E(bar(X))= 1.4 var(bar(X))= 0.28
1.397 0.2709419
> CLT.Pois(25,1.4)
E(bar(X))= 1.4 var(bar(X))= 0.056
1.39548 0.05730888
> CLT.Pois(100,1.4)
E(bar(X))= 1.4 var(bar(X))= 0.014
1.40731 0.01457444
```

