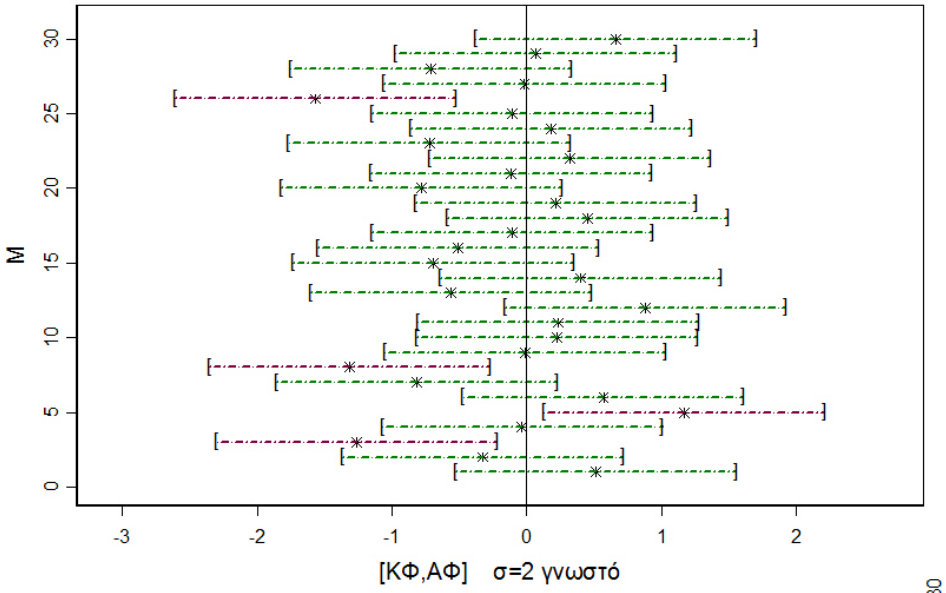
Θέματα Στατιστικής στη γλώσσα R

- **Διαστήματα εμπιστοσύνης**
  - ✓ η ερμηνεία του σ.ε.
  - ✓ η σχέση με το μέγεθος του δείγματος

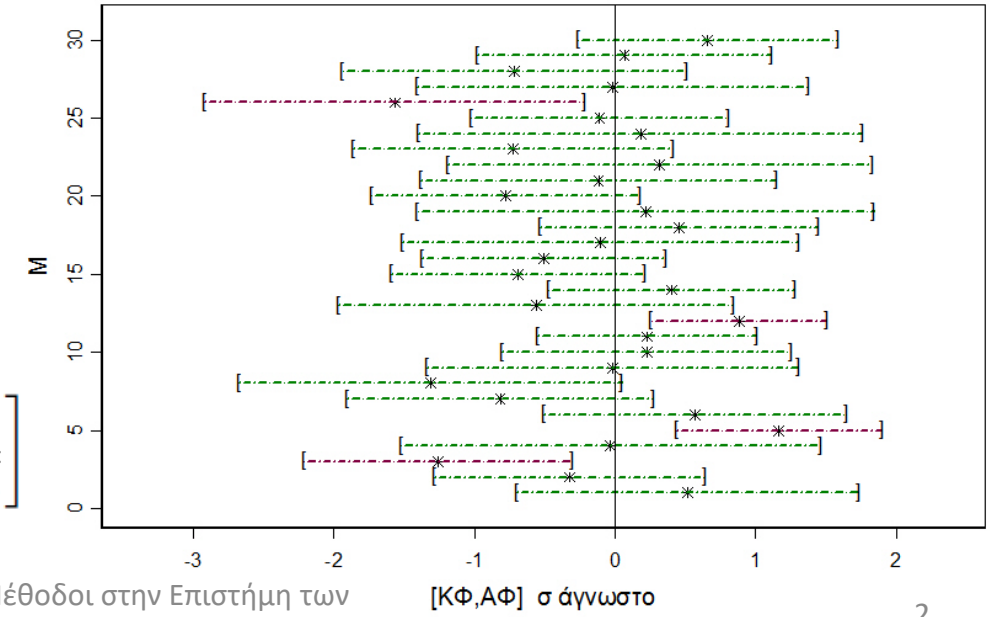
- **Ποσότητες οδηγοί και τα ποσοστιαία σημεία των αντίστοιχων κατανομών**
  - ✓ N(0,1)
  - ✓ Student's t
  - ✓ $\mathcal{X}^2$, *F*

- **Διαστήματα εμπιστοσύνης**
  - ➢ ένα δείγμα
    - ✓ για τη μέση τιμή κανονικής
      - ❖ διασπορά γνωστή
      - ❖ διασπορά άγνωστη

Διαστήματα Εμπιστοσύνης



$$\left[\overline{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$



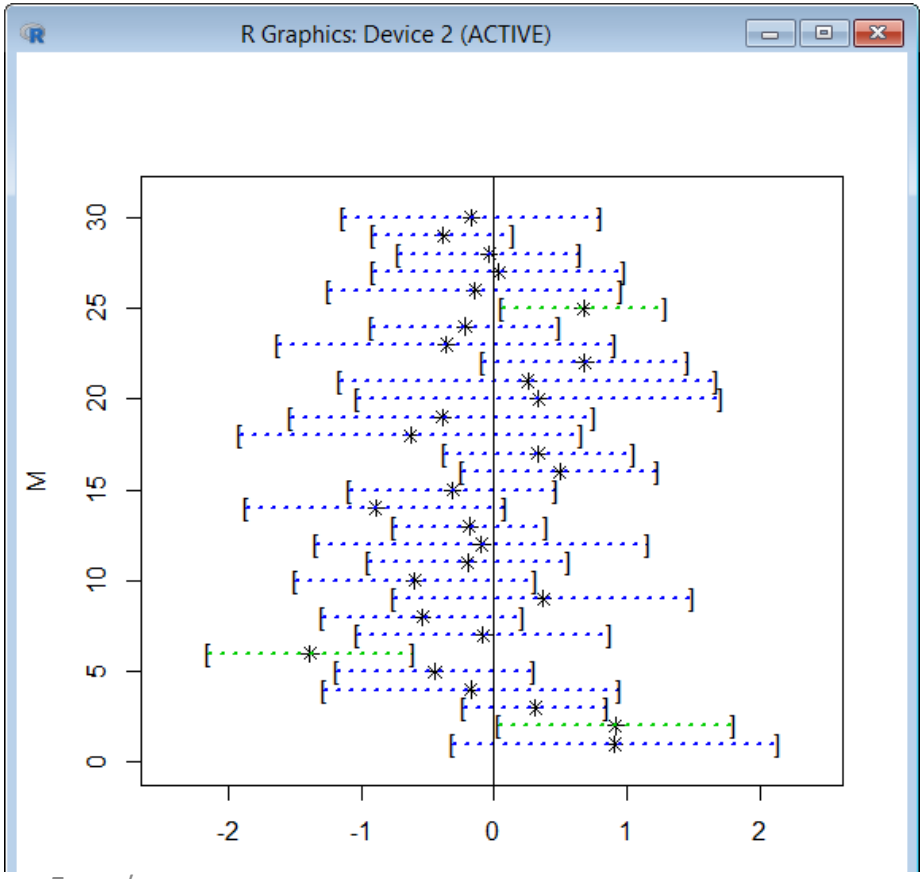
$$\left[\overline{X} - t_{n-1}(\alpha/2)\frac{S}{\sqrt{n}},\ \overline{X} + t_{n-1}(\alpha/2)\frac{S}{\sqrt{n}}\right]$$

Διαστήματα Εμπιστοσύνης: η ερμηνεία του σ.ε.

```
> s
 [1] 1.819709 1.654812 1.352845 1.052756 1.397919 1.785158
 [7] 1.794624 1.260199 1.748311 1.126880 1.678715 1.615690
[13] 1.466358 1.387275 1.885143 1.164992 1.100625 1.750822
[19] 1.776309 1.914089 1.936415 1.056705 1.807750 1.276713
[25] 1.689612 1.441474 1.533761 1.631297 1.049493 1.491035
```

```
> N2(30,10,0.1,0,s)
Waiting to confirm page change..
 [1] 2.441024 1.771613 1.081134
 [4] 2.218797 1.488548 1.542167
 [7] 1.895853 1.503706 2.238480
[10] 1.805696 1.507070 2.483619
[13] 1.138120 1.940759 1.549560
[16] 1.462575 1.419440 2.562162
[19] 2.284833 2.727073 2.821752
[22] 1.526949 2.532931 1.409244
[25] 1.236595 2.193413 1.878055
[28] 1.360058 1.051815 1.926961
```

εύρος των διαστημάτων που κατασκευάστηκαν

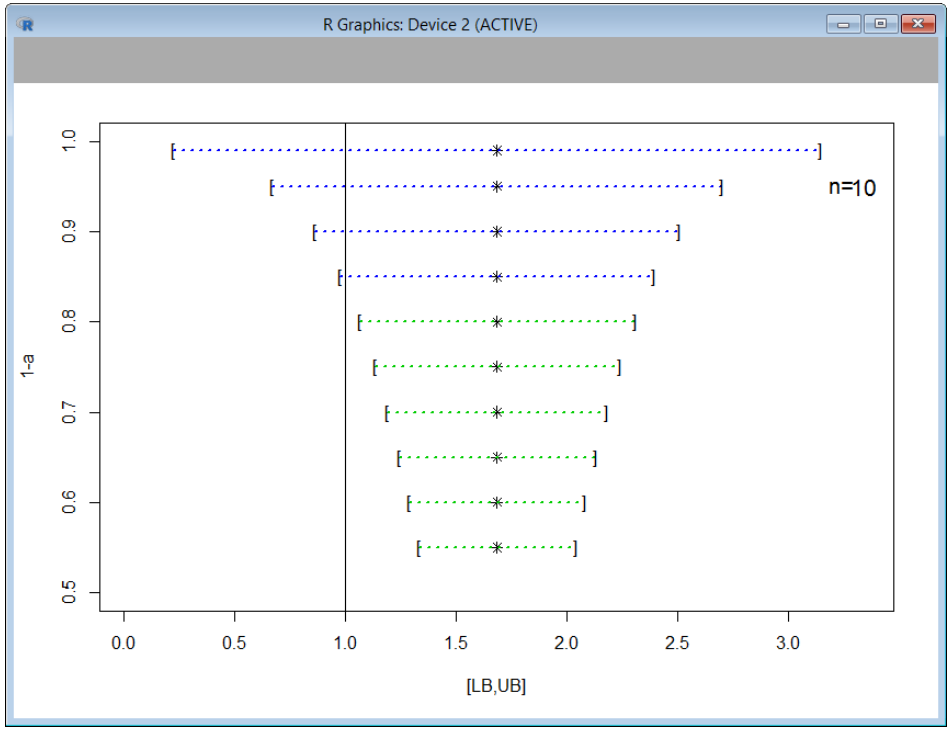


Κώδικας

```
> N2<-function(M,n,a,m,s) {
+ y<-array(rep(0,2*M),dim=c(M,2))
+ for (i in 1:M) {
+ x<-rnorm(n,m,s[i])
+ y[i,1]<-mean(x)+qt(a/2,n-1)*sqrt(var(x)/n)
+ y[i,2]<-mean(x)+qt(1-a/2,n-1)*sqrt(var(x)/n)
+ }
+ for (i in 1:M) {
+ if  (i==1) {
+ plot((y[1,1]+y[1,2])/2,1,pch=8,xlim=c(min(y[,1])-0.3,max(y[,2])+0.3)
+ }
+ if ((y[i,1]>m)||(y[i,2]<m)){
+ points((y[i,1]+y[i,2])/2,i,pch=8,col=1)
+ lines(c(y[i,1],y[i,2]),c(i,i),lty = 3,lwd=2.2,col=3)
+ text(y[i,1],i,"[",col=1)
+ text(y[i,2],i,"]",col=1)}
+ if ((y[i,1]<m)&(y[i,2]>m)){
+ points((y[i,1]+y[i,2])/2,i,pch=8,col=1)
+ lines(c(y[i,1],y[i,2]),c(i,i),lty = 3,lwd=2.2,col=4)
+ text(y[i,1],i,"[",col=1)
+ text(y[i,2],i,"]",col=1)}
+ }
+ abline(v = m,col=1)
+ print(y[,2]-y[,1])
+ }
> s<-runif(30,1,2)
```

Διαστήματα Εμπιστοσύνης: η ερμηνεία του σ.ε.

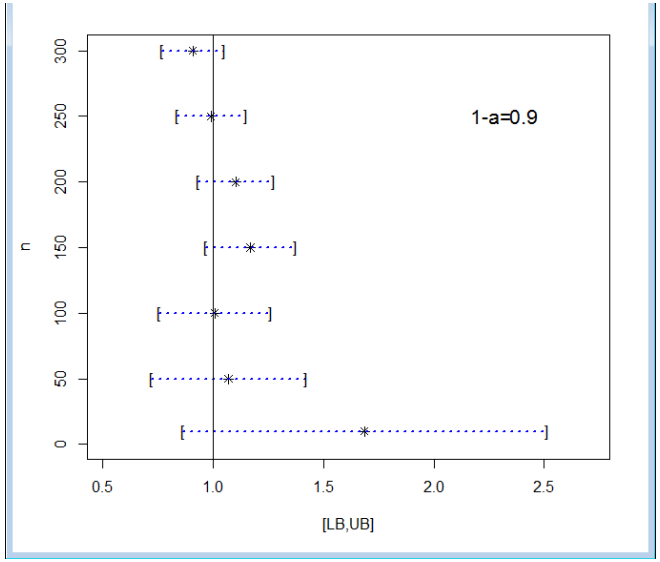
```
> x
 [1] 5.09787041 2.28965487 2.43218122 0.86540021
 [5] 0.91974851 0.55373450 1.28536466 1.22803143
 [9] 0.08675835 2.09133592
> c(mean(x),var(x))
[1] 1.685008 2.021856
```

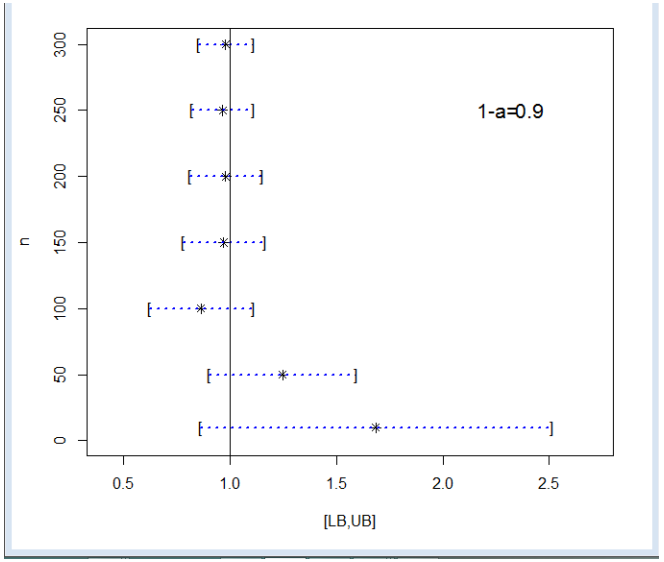


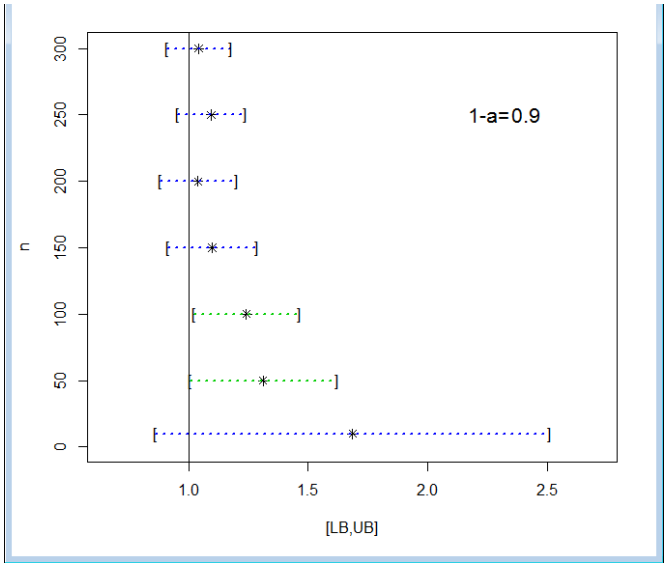
Κώδικας

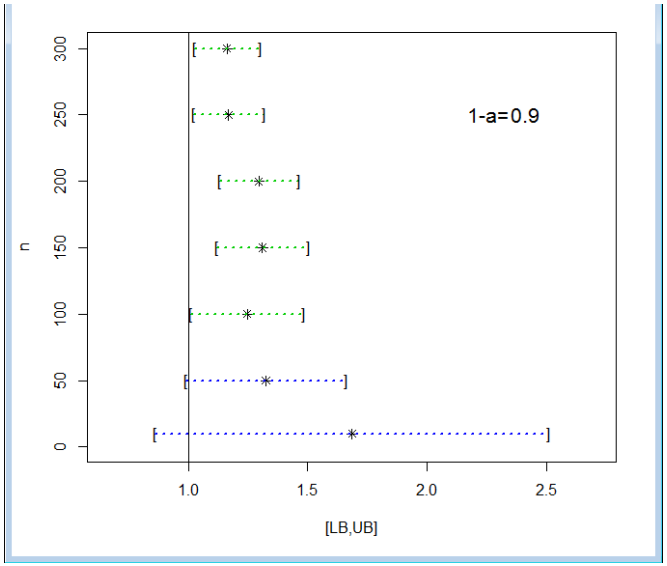
```
> m<-1
> s<-sqrt(var(x))
> A<-c(0.01,0.05,0.1,0.15,0.2,0.25,0.3,0.35,0.4,0.45)
> A<-sort(A)
> CL<-1-A
> # various c.l.
> n1<-length(A)
> y<-array(rep(0,2*n1),dim=c(n1,2))
> i<-0
> for (a in A) {
+ i<-i+1
+ y[i,1]<-mean(x)+qt(a/2,n-1)*s/sqrt(n)
+ y[i,2]<-mean(x)+qt(1-a/2,n-1)*s/sqrt(n)
+ }
> for (i in 1:n1) {
+ if  (i==1) {
+ plot((y[1,1]+y[1,2])/2,CL[1],pch=8,xlim=c(min(y[,1])-0.2,max(y[,2])+0.2),yli$
+ }
+ if ((y[i,1]>m)||(y[i,2]<m)){
+ points((y[i,1]+y[i,2])/2,CL[i],pch=8,col=1)
+ lines(c(y[i,1],y[i,2]),c(CL[i],CL[i]),lty = 3,lwd=2.2,col=3)
+ text(y[i,1],CL[i],"[",col=1)
+ text(y[i,2],CL[i],"]",col=1)}
+ if ((y[i,1]<m)&(y[i,2]>m)){
+ points((y[i,1]+y[i,2])/2,CL[i],pch=8,col=1)
+ lines(c(y[i,1],y[i,2]),c(CL[i],CL[i]),lty = 3,lwd=2.2,col=4)
+ text(y[i,1],CL[i],"[",col=1)
+ text(y[i,2],CL[i],"]",col=1)}
+ }
Waiting to confirm page change...
> abline(v = m,col=1)
> text(max(y[,2])+0.1,0.95,"n=",cex=1.3)
> text(max(y[,2])+0.2,0.95,n,cex=1.3)
```

Διαστήματα Εμπιστοσύνης και μέγεθος δείγματος









Ποσότητες οδηγοί - ποσοστιαία σημεία των αντίστοιχων κατανομών

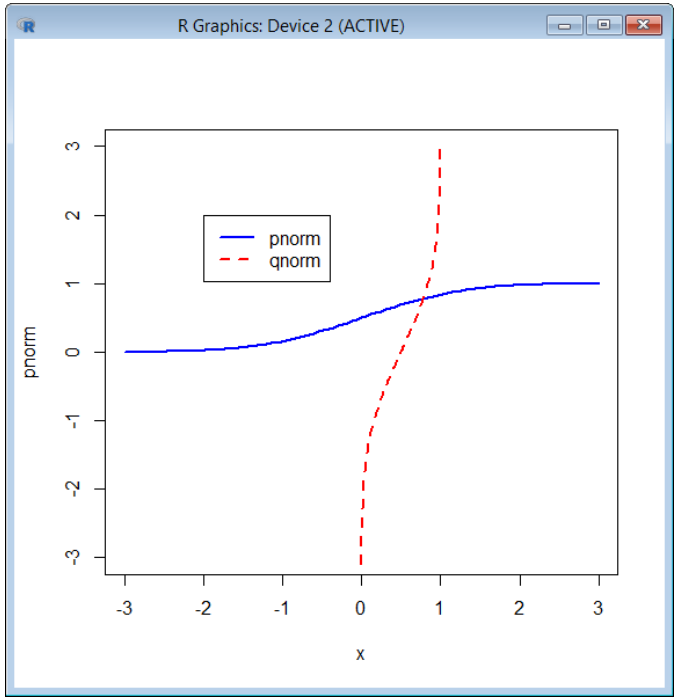
$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow \boxed{\frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)}$$

Η α.σ.κ. της N(0,1), Φ(x), και η $\Phi^{-1}(p)$

$\Phi: \mathbb{R} \rightarrow [0,1]$ $\Phi(x)=P(Z_i \leq x)$

$\Phi^{-1}:(0,1) \rightarrow \mathbb{R}$




```
> plot(pnorm,xlim=c(-3,3),ylim=c(-3,3),col="blue",lwd=2)
> curve(qnorm(x),xlim=c(0.001,0.999),add=T,col="red",lty=2,lwd=2)
> legend(-2,2,legend=c("pnorm","qnorm"),col=c("blue","red"),lty=c(1,2),lwd=2)
```

Η α.σ.κ. της N(0,1), Φ(x), η $\Phi^{-1}(p)$ και τα z_α

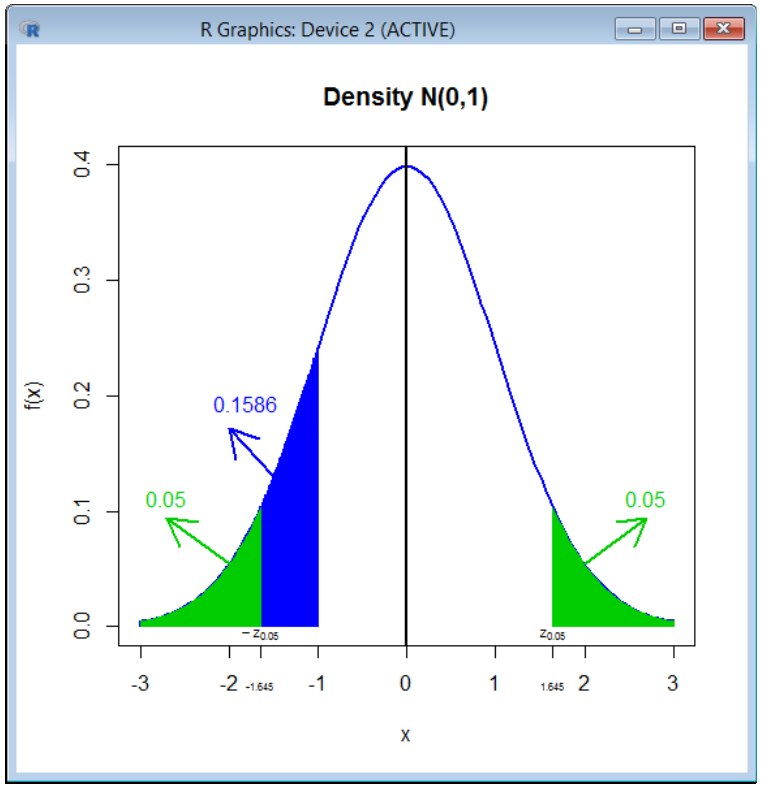
$\Phi(z_\alpha)=1-\alpha$

$z_\alpha=\Phi^{-1}(1-\alpha)$ $\quad z_\alpha$=qnorm(1-α)

$\Phi(-z_\alpha)=1-\Phi(z_\alpha)=\alpha$

$-z_\alpha=\Phi^{-1}(\alpha)$ $\quad -z_\alpha$=qnorm(α)

z_α=-qnorm(α)




```
> pnorm(-2)
[1] 0.02275013
> pnorm(-1)
[1] 0.1586553
> pnorm(c(0,1,2,3))
[1] 0.5000000 0.8413447 0.9772499 0.9986501
> qnorm(0.05)
[1] -1.644854
> qnorm(0.5)   #median
[1] 0
> qnorm(0.95)
[1] 1.644854
```

Η α.σ.κ. της χ^2, F(x), η $F^{-1}(p)$ και τα $\chi^2_{v,\alpha}$

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\sum_{i=1}^{n} \frac{(X_i - \mu)^2}{\sigma^2} \sim \chi^2_n$$

$$(n-1)\frac{S^2}{\sigma^2} = \sum_{i=1}^{n} \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{n-1}$$

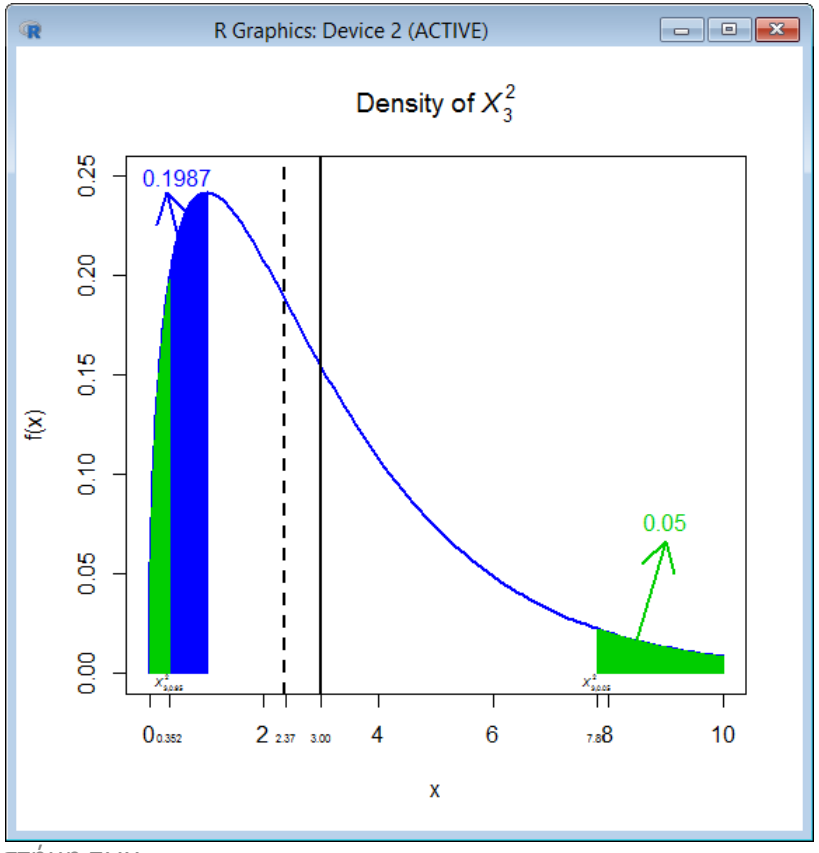
$F(\chi^2_{v,\alpha})=1-\alpha$

$\chi^2_{v,\alpha}=F^{-1}(1-\alpha)$ $\chi^2_{v,\alpha}$=qchisq(1-α ,df=v)

$F(\chi^2_{v,1-\alpha})=\alpha$

$\chi^2_{v,1-\alpha}=F^{-1}(\alpha)$ $\chi^2_{v,1-\alpha}$=qchisq(α,v)

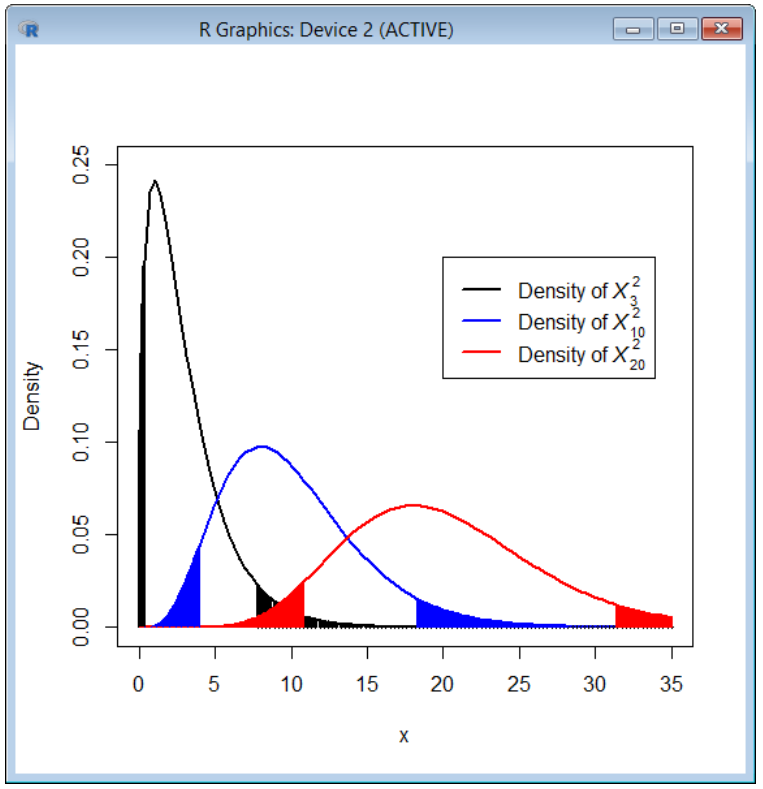
```
> v<-3
> pchisq(-1,df=v)
[1] 0
> pchisq(c(1,3,9),v)
[1] 0.1987480 0.6083748 0.9707091
> qchisq(0.05,v)
[1] 0.3518463
> qchisq(0.5,v)   #median
[1] 2.365974
> qchisq(0.95,v)
[1] 7.814728
```



Τα ποσοστιαία σημεία $\chi^2_{\nu,\alpha}$ για διάφορα ν

```
> #df=10
> v<-10
> pchisq(c(1,10,23),v)
[1] 0.0001721156 0.5595067149 0.9892534216
> qchisq(0.05,v)
[1] 3.940299
> qchisq(0.5,v)   #median
[1] 9.341818
> qchisq(0.95,v)
[1] 18.30704

> #df=20
> v<-20
> qchisq(0.05,v)
[1] 10.85081
> pchisq(c(1,20,36),v)
[1] 1.709670e-10 5.420703e-01 9.846189e-01
> qchisq(0.5,v)    #median
[1] 19.33743
> qchisq(0.95,v)
[1] 31.41043
```



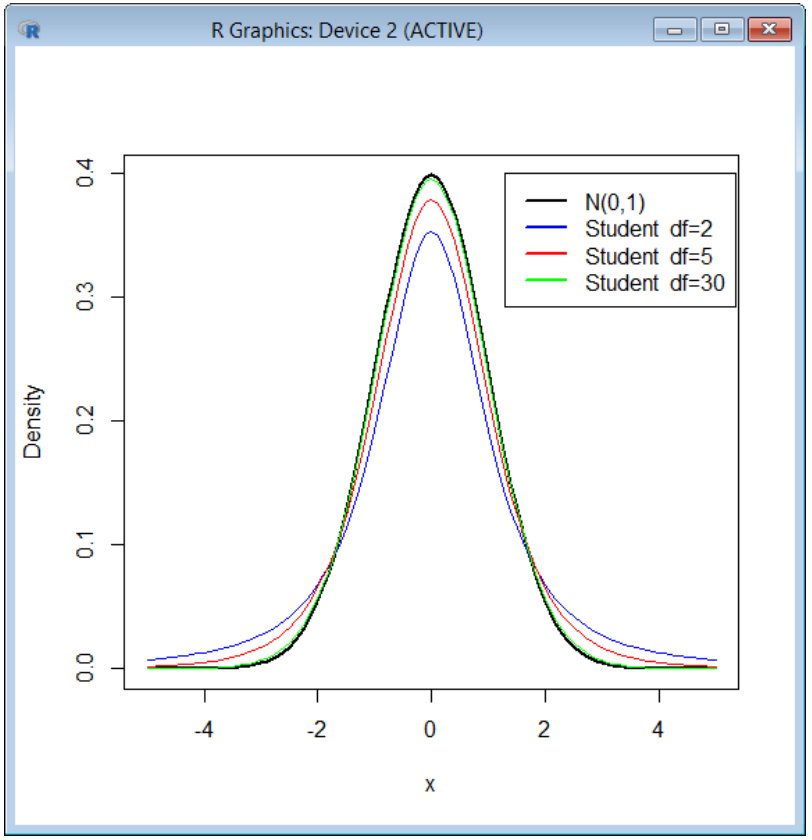
Τυπική κανονική κατανομή και Student's t κατανομή

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

$$\frac{\overline{X} - \mu}{\frac{S}{\sqrt{n}}} = \frac{\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{\frac{\overline{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)\frac{S^2}{\sigma^2}}{n-1}}} \equiv \frac{N(0,1)}{\sqrt{\frac{\chi^2_{n-1}}{n-1}}}$$

$\overline{X}$ και S^2 ανεξάρτητες




```
> plot(dnorm,xlim=c(-5,5),lwd=2,ylab="Density")
> curve(dt(x,df=2),xlim=c(-5,5),col="blue",add=T)
> curve(dt(x,df=5),xlim=c(-5,5),col="red",add=T)
> curve(dt(x,df=30),xlim=c(-5,5),col="green",add=T)
> legend(1.3,0.4,legend=c("N(0,1)","Student  df=2",
+       "Student  df=5","Student  df=30"),col=c(1,"blue","red","green"),
```

Τα ποσοστιαία σημεία $t_{\nu;\alpha}$ και βαθμοί ελευθερίας

$F(t_{\nu,\alpha})=1-\alpha$

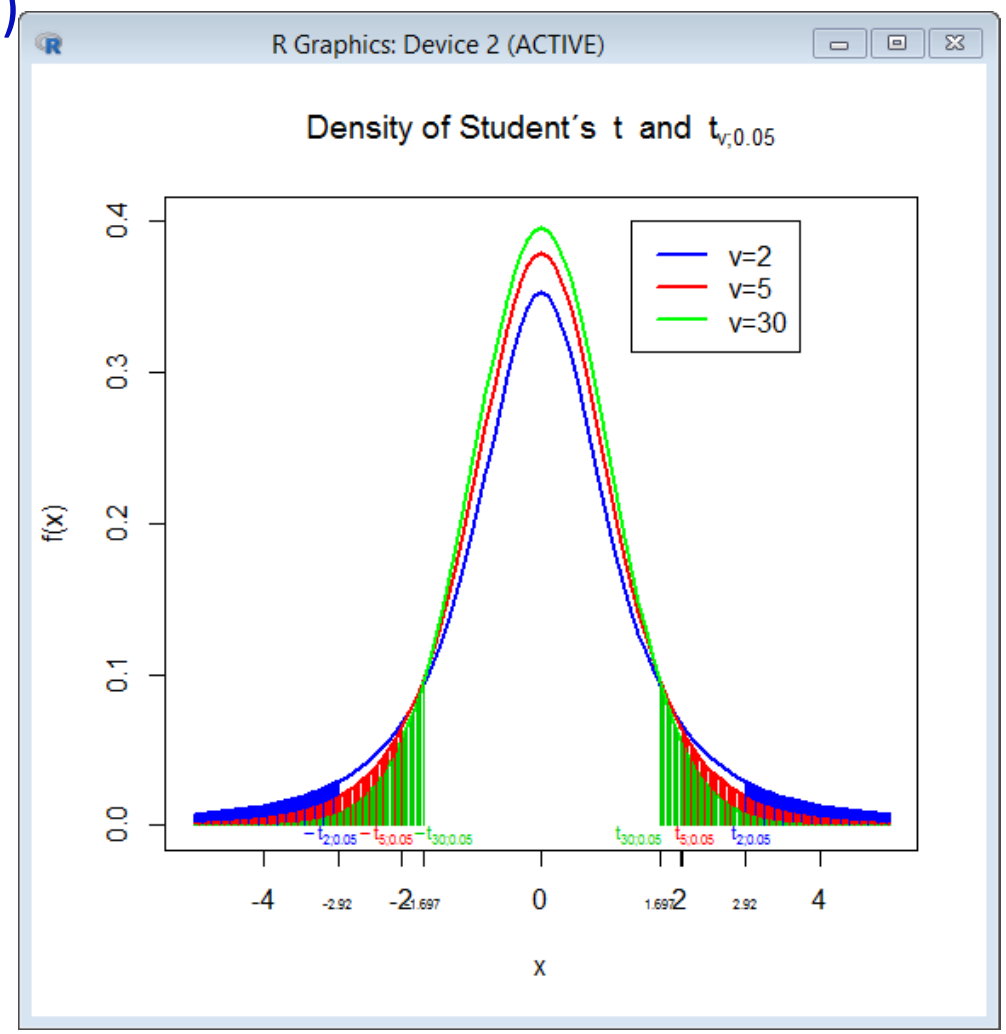
$\mathbf{t_{\nu,\alpha}}=F^{-1}(1-\alpha)$ $\quad t_{\nu,\alpha}=qt(1-\alpha, df=v)$

$F(-t_{\nu,\alpha})=\alpha$

$\mathbf{-t_{\nu,\alpha}}=F^{-1}(\alpha)$ $\quad -t_{\nu,\alpha}=qt(\alpha,v)$

$t_{\nu,\alpha}=-qt(\alpha,v)$

```
> pt(-2,df=2)
[1] 0.09175171
> qt(0.05,df=2)
[1] -2.919986
> qt(0.05,df=5)
[1] -2.015048
> qt(0.05,df=30)
[1] -1.697261
> qt(0.95,df=c(2,5,30,50,100))
[1] 2.919986 2.015048 1.697261
[4] 1.675905 1.660234
> qnorm(0.95)
[1] 1.644854
```



Διαστήματα εμπιστοσύνης

- ✓ ένα δείγμα από κανονική κατανομή

Δ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά γνωστή

$$\left[\bar{X} - z_{a/2}\frac{\sigma}{\sqrt{n}}\ ,\ \bar{X} + z_{a/2}\frac{\sigma}{\sqrt{n}}\right]$$

```
c(Mx+qnorm(a/2)*sigma/sqrt(n),Mx+qnorm(1-a/2)*sigma/sqrt(n))

sigma      #sas to divw

n<-length(x)
Mx<-mean(x)
```

```
> x
 [1] -1.26 -2.05  3.77  3.88 -2.24  0.13 -2.47  0.18  4.90 -1.76
> n
[1] 10
> Mx
[1] 0.308
> for (a in c(0.05,0.1,0.2)){
+ cat("s.e. 1-a=",1-a,
+ "LB=",round(Mx+qnorm(a/2)*sigma/sqrt(n),4),
+ "UB=",round(Mx+qnorm(1-a/2)*sigma/sqrt(n),4),"\n")
+ }
s.e. 1-a= 0.95 LB= -1.5514 UB= 2.1674
s.e. 1-a= 0.9 LB= -1.2524 UB= 1.8684
s.e. 1-a= 0.8 LB= -0.9078 UB= 1.5238
```

Διαστήματα εμπιστοσύνης

- ✓ **ένα δείγμα από κανονική κατανομή**

Δ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά άγνωστη

$$\left[\bar{X} - t_{n-1,a/2}\frac{S}{\sqrt{n}}\ ,\ \ \bar{X} + t_{n-1,a/2}\frac{S}{\sqrt{n}}\right]$$

```
# METHOD A

c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))

n<-length(x)
Mx<-mean(x)
S<-sd(x)
```

```
# METHOD B    1-a=0.95
t.test(x)
```

Α.Φ.Ε. και Κ.Φ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά άγνωστη

$$\bar{X} - t_{n-1,a}\frac{S}{\sqrt{n}} \rightsquigarrow \text{Κ.Φ.Ε.} \qquad \bar{X} + t_{n-1,a}\frac{S}{\sqrt{n}} \rightsquigarrow \text{Α.Φ.Ε.}$$

```
t.test(x,alternative="greater")

t.test(x,alternative="less")
```

Διαστήματα εμπιστοσύνης

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
- ✓ δεν έχω τις παρατηρήσεις, μόνον τις δειγματικές παραμέτρους

Άσκηση 1

X : μετράει την επιφάνεια που καλύφθηκε από το χρώμα των κουτιών,

$$X_1, \ldots, X_{12} \text{ τυχαίο δείγμα } \sim \mathcal{N}(\mu, \sigma^2)$$

$$\left[\bar{X} - t_{n-1,a/2}\frac{S}{\sqrt{n}}\ ,\ \ \bar{X} + t_{n-1,a/2}\frac{S}{\sqrt{n}}\right]$$

$$\bar{X} = 65\ ,\ \ s = 3\ ,\ \ n = 12\ ,\ \ 1 - a = 0.9\ ,\ \ t_{11,0.05} = 1.796$$

$$(63.44\ ,\ \ 66.56)$$

```
> n<-12
> Mx<-65
> S<-3
> cat("n=",n,"Mx=",Mx,"S^2=",S^2,"\n")
n= 12 Mx= 65 S^2= 9
> for (a in c(0.05,0.1,0.2)){
+ cat("s.e. 1-a=",1-a,"  t",n-1,"(",a/2,")=",round(qt(1-a/2,n-1),3),
+ "  [",round(Mx+qt(a/2,n-1)*S/sqrt(n),4),",",
+ round(Mx+qt(1-a/2,n-1)*S/sqrt(n),4),"]","\n")
+ }
s.e. 1-a= 0.95   t 11 ( 0.025 )= 2.201   [ 63.0939 , 66.9061 ]
s.e. 1-a= 0.9   t 11 ( 0.05 )= 1.796   [ 63.4447 , 66.5553 ]
s.e. 1-a= 0.8   t 11 ( 0.1 )= 1.363   [ 63.8192 , 66.1808 ]
```

Διαστήματα εμπιστοσύνης

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
- ✓ έχω τις παρατηρήσεις

The data are weight changes of humans, tabulated after administration of a drug proposed to result in weight loss. Each weight change (in kg) is the weight after minus the weight before drug administration.

0.2 -0.5 -1.3 -1.6 -0.7 0.4 -0.1 0.0 -0.6 -1.1 -1.2 -0.8

mean of x: -0.6083333

95 percent confidence interval: [-1.0105948, -0.2060719]

90 percent confidence interval: [-0.9365569, -0.2801098]

95 percent confidence interval: [-0.9365569, Inf)

95 percent confidence interval: (–Inf, -0.2801098]

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
  - ✓ έχω τις παρατηρήσεις (συνέχεια…)

```
> x<-scan()
1: 0.2 -0.5 -1.3 -1.6 -0.7 0.4 -0.1 0.0 -0.6 -1.1 -1.2 -0.8
13:
Read 12 items
> n<-length(x)
> Mx<-mean(x)
> S<-sd(x)
> cat("n=",n,"Mx=",Mx,"S^2=",var(x),"\n")
n= 12 Mx= -0.6083333 S^2= 0.4008333
> # 95% Conf Inter for m
> # METHOD A
> a<-0.05
> c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))
[1] -1.0105948 -0.2060719
> # METHOD B   1-a=0.95
> t.test(x)

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.006729
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -1.0105948 -0.2060719
sample estimates:
 mean of x
-0.6083333
```

- ✓ **ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά**
  - ✓ **έχω τις παρατηρήσεις (συνέχεια…)**

```
> a<-0.1
> # METHOD A
> c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))
[1] -0.9365569 -0.2801098
> # METHOD B
> t.test(x,conf.level=1-a)

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.006729
alternative hypothesis: true mean is not equal to 0
90 percent confidence interval:
 -0.9365569 -0.2801098
sample estimates:
 mean of x
-0.6083333
```

- ✓ ένα δείγμα από κανονική κατανομή, ΚΦ και ΑΦ για τη μέση τιμή, άγνωστη διασπορά
  - ✓ έχω τις παρατηρήσεις (συνέχεια…)

```
> t.test(x,alternative="greater")

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.9966
alternative hypothesis: true mean is greater than 0
95 percent confidence interval:
 -0.9365569        Inf
sample estimates:
 mean of x
-0.6083333

> t.test(x,alternative="less")

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.003364
alternative hypothesis: true mean is less than 0
95 percent confidence interval:
       -Inf -0.2801098
sample estimates:
 mean of x
-0.6083333
```