Θέματα Στατιστικής στη γλώσσα R

- **Ποσότητες οδηγοί και τα ποσοστιαία σημεία των αντίστοιχων κατανομών**
  - ✓ **N(0,1)**
  - ✓ **Student's t**
  - ✓ χ^2, ***F***
- **Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων**
  - ➢ **ένα δείγμα**
    - ✓ **για τη μέση τιμή κανονικής**
      - ❖ **διασπορά γνωστή**
      - ❖ **διασπορά άγνωστη**
    - ✓ **για τη διασπορά κανονικής**
    - ✓ **για ποσοστό**
  - ➢ **δύο ανεξάρτητα δείγματα**
    - ✓ **για τη διαφορά των μέσων τιμών δύο κανονικών**
      - ❖ **ίσες διασπορές**
      - ❖ **άνισες διασπορές**
    - ✓ **για το πηλίκο των διασπορών δύο κανονικών**
    - ✓ **για τη διαφορά ποσοστών**

Ποσότητες οδηγοί - ποσοστιαία σημεία των αντίστοιχων κατανομών

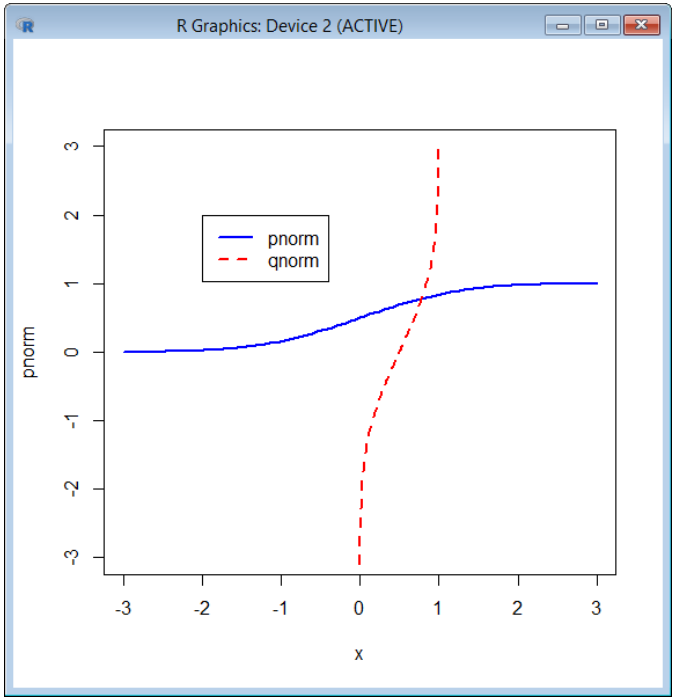
$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow \boxed{\frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)}$$

Η α.σ.κ. της N(0,1), Φ(x), και η $\Phi^{-1}(p)$

$\Phi: \mathbb{R} \rightarrow [0,1]$ $\Phi(x)=P(Z_i \leq x)$

$\Phi^{-1}:(0,1) \rightarrow \mathbb{R}$




```
> plot(pnorm,xlim=c(-3,3),ylim=c(-3,3),col="blue",lwd=2)
> curve(qnorm(x),xlim=c(0.001,0.999),add=T,col="red",lty=2,lwd=2)
> legend(-2,2,legend=c("pnorm","qnorm"),col=c("blue","red"),lty=c(1,2),lwd=2)
```

Η α.σ.κ. της N(0,1), Φ(x), η $\Phi^{-1}(p)$ και τα z_α

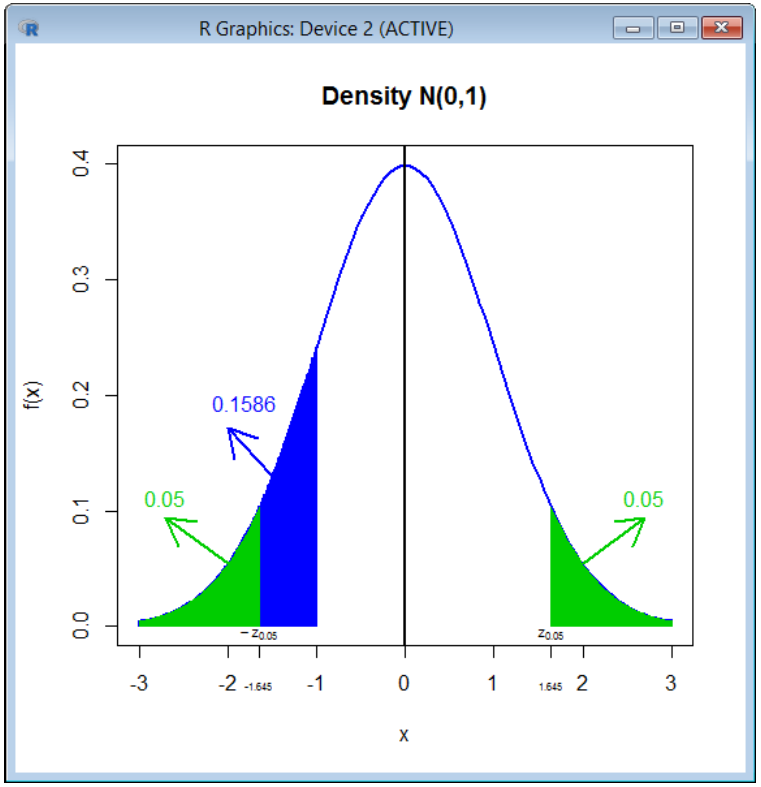
$\Phi(z_\alpha)=1-\alpha$

$z_\alpha=\Phi^{-1}(1-\alpha)$ $\quad z_\alpha=$qnorm(1-α)

$\Phi(-z_\alpha)=1-\Phi(z_\alpha)=\alpha$

$-z_\alpha=\Phi^{-1}(\alpha)$ $\quad -z_\alpha=$qnorm(α)

$z_\alpha=$-qnorm(α)




```
> pnorm(-2)
[1] 0.02275013
> pnorm(-1)
[1] 0.1586553
> pnorm(c(0,1,2,3))
[1] 0.5000000 0.8413447 0.9772499 0.9986501
> qnorm(0.05)
[1] -1.644854
> qnorm(0.5)   #median
[1] 0
> qnorm(0.95)
[1] 1.644854
```

Η α.σ.κ. της χ^2, F(x), η $F^{-1}(p)$ και τα $\chi^2_{v,\alpha}$

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\sum_{i=1}^{n} \frac{(X_i - \mu)^2}{\sigma^2} \sim \chi^2_n$$

$$(n-1)\frac{S^2}{\sigma^2} = \sum_{i=1}^{n} \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{n-1}$$

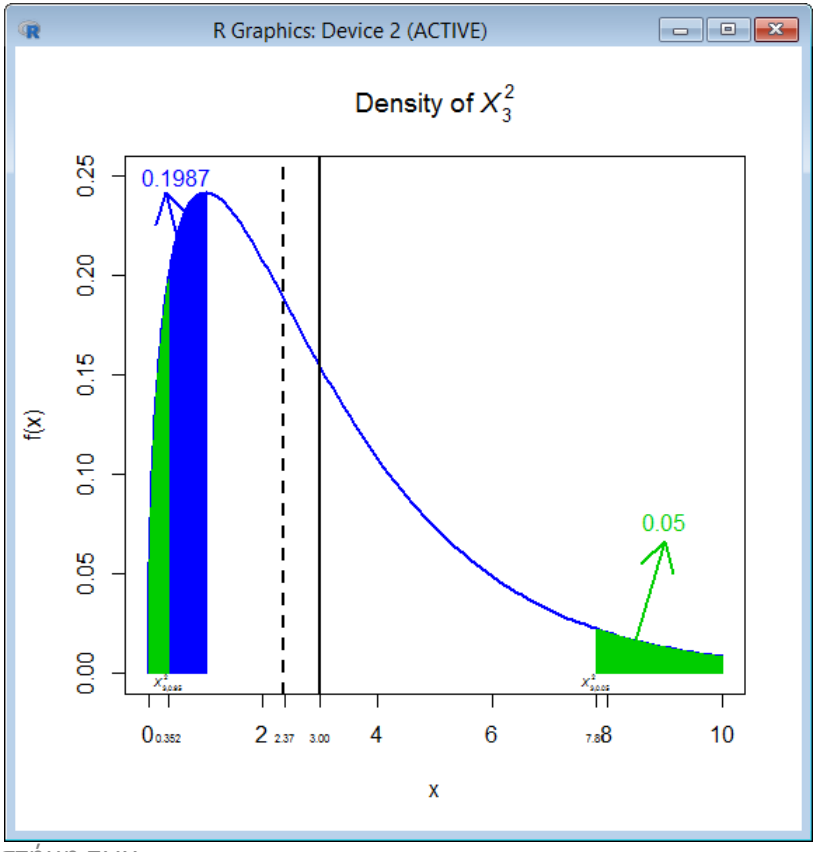
$F(\chi^2_{v,\alpha})=1-\alpha$

$\chi^2_{v,\alpha} = F^{-1}(1-\alpha)$ $\chi^2_{v,\alpha}$=qchisq(1-α ,df=v)

$F(\chi^2_{v,1-\alpha})=\alpha$

$\chi^2_{v,1-\alpha} = F^{-1}(\alpha)$ $\chi^2_{v,1-\alpha}$=qchisq(α,v)

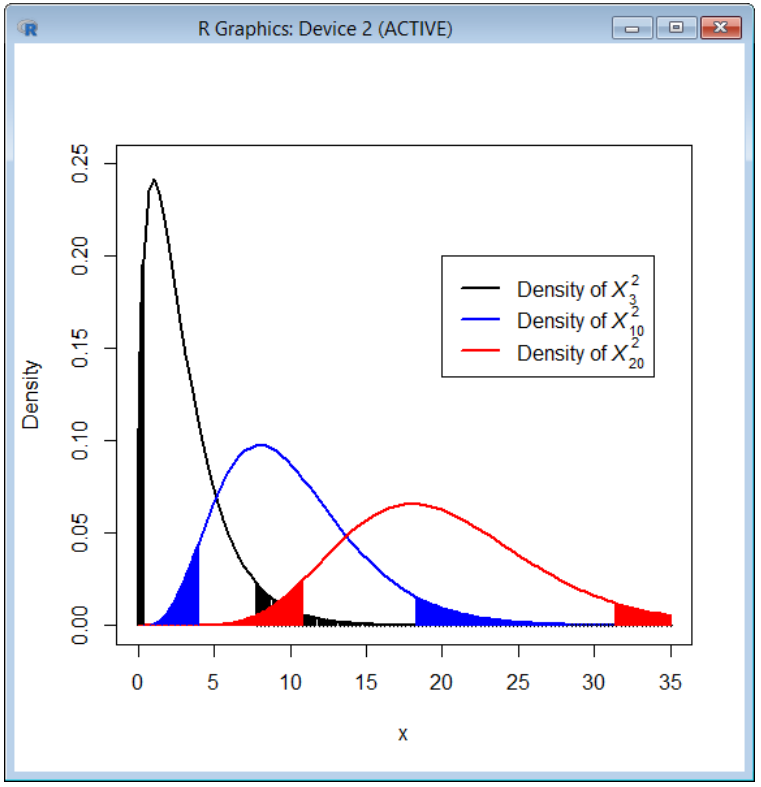
```
> v<-3
> pchisq(-1,df=v)
[1] 0
> pchisq(c(1,3,9),v)
[1] 0.1987480 0.6083748 0.9707091
> qchisq(0.05,v)
[1] 0.3518463
> qchisq(0.5,v)   #median
[1] 2.365974
> qchisq(0.95,v)
[1] 7.814728
```



Τα ποσοστιαία σημεία $\chi^2_{\nu,\alpha}$ για διάφορα ν

```
> #df=10
> v<-10
> pchisq(c(1,10,23),v)
[1] 0.0001721156 0.5595067149 0.9892534216
> qchisq(0.05,v)
[1] 3.940299
> qchisq(0.5,v)   #median
[1] 9.341818
> qchisq(0.95,v)
[1] 18.30704

> #df=20
> v<-20
> qchisq(0.05,v)
[1] 10.85081
> pchisq(c(1,20,36),v)
[1] 1.709670e-10 5.420703e-01 9.846189e-01
> qchisq(0.5,v)    #median
[1] 19.33743
> qchisq(0.95,v)
[1] 31.41043
```



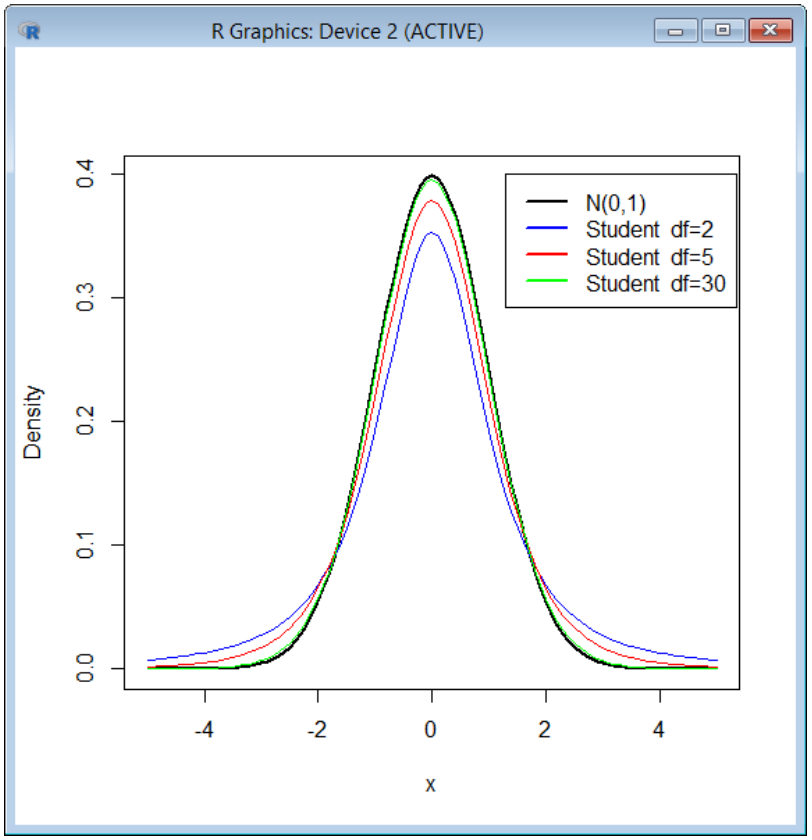
Τυπική κανονική κατανομή και Student's t κατανομή

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα από $N(\mu, \sigma^2)$

$$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$$

$$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} = \frac{\frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{\frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)\frac{S^2}{\sigma^2}}{n-1}}} \equiv \frac{N(0,1)}{\sqrt{\frac{\chi^2_{n-1}}{n-1}}}$$

$\bar{X}$ και S^2 ανεξάρτητες




```
> plot(dnorm,xlim=c(-5,5),lwd=2,ylab="Density")
> curve(dt(x,df=2),xlim=c(-5,5),col="blue",add=T)
> curve(dt(x,df=5),xlim=c(-5,5),col="red",add=T)
> curve(dt(x,df=30),xlim=c(-5,5),col="green",add=T)
> legend(1.3,0.4,legend=c("N(0,1)","Student  df=2",
+       "Student  df=5","Student  df=30"),col=c(1,"blue","red","green"),
```

Τα ποσοστιαία σημεία $t_{\nu;\alpha}$ και βαθμοί ελευθερίας

$F(t_{\nu,\alpha})=1-\alpha$

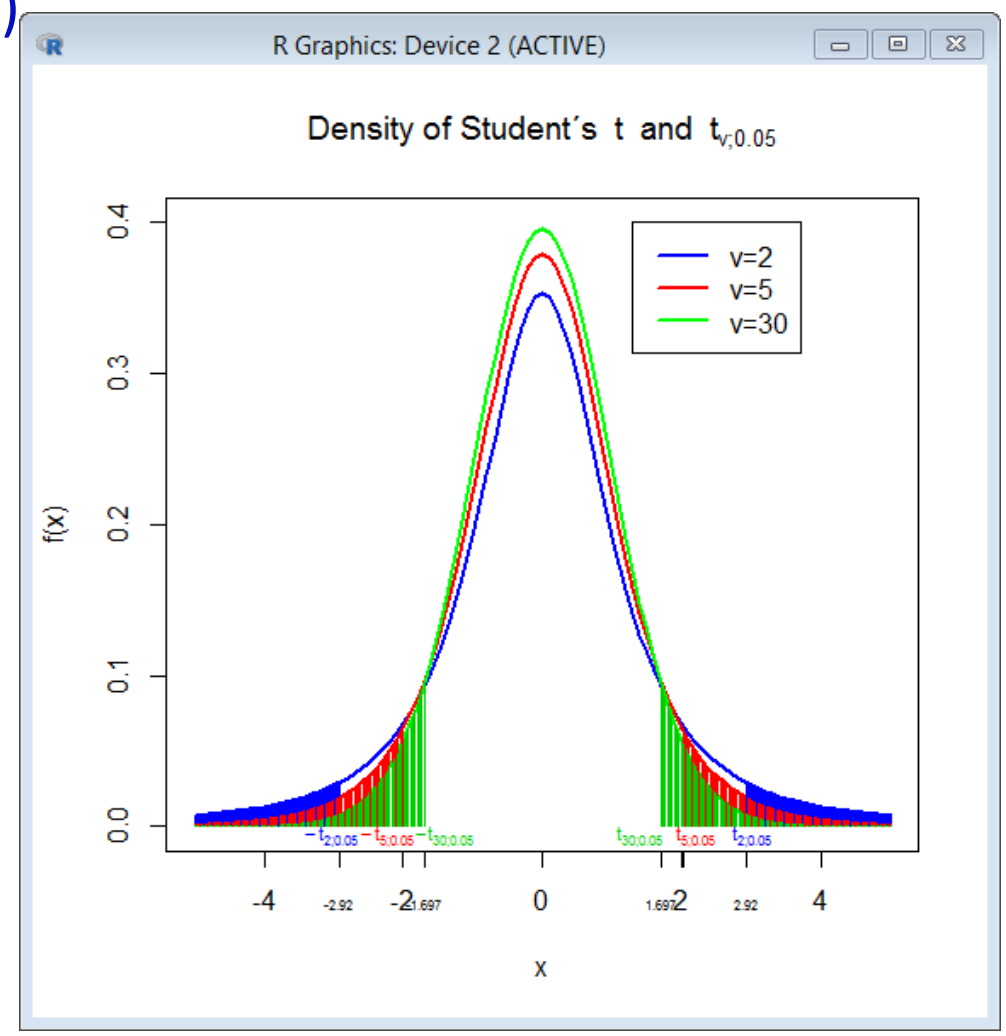
$\mathbf{t_{\nu,\alpha}}=F^{-1}(1-\alpha)$ $\quad t_{\nu,\alpha}=qt(1-\alpha, df=\nu)$

$F(-t_{\nu,\alpha})=\alpha$

$\mathbf{-t_{\nu,\alpha}}=F^{-1}(\alpha)$ $\quad -t_{\nu,\alpha}=qt(\alpha,\nu)$

$t_{\nu,\alpha}=-qt(\alpha,\nu)$

```
> pt(-2,df=2)
[1] 0.09175171
> qt(0.05,df=2)
[1] -2.919986
> qt(0.05,df=5)
[1] -2.015048
> qt(0.05,df=30)
[1] -1.697261
> qt(0.95,df=c(2,5,30,50,100))
[1] 2.919986 2.015048 1.697261
[4] 1.675905 1.660234
> qnorm(0.95)
[1] 1.644854
```



Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ ένα δείγμα από κανονική κατανομή

Δ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά γνωστή

$$\left[\bar{X} - z_{a/2}\frac{\sigma}{\sqrt{n}}\ ,\ \bar{X} + z_{a/2}\frac{\sigma}{\sqrt{n}}\right]$$

```
c(Mx+qnorm(a/2)*sigma/sqrt(n),Mx+qnorm(1-a/2)*sigma/sqrt(n))

sigma      #sas to divw

n<-length(x)
Mx<-mean(x)
```

```
> x
 [1] -1.26 -2.05  3.77  3.88 -2.24  0.13 -2.47  0.18  4.90 -1.76
> n
[1] 10
> Mx
[1] 0.308
> for (a in c(0.05,0.1,0.2)){
+ cat("s.e. 1-a=",1-a,
+ "LB=",round(Mx+qnorm(a/2)*sigma/sqrt(n),4),
+ "UB=",round(Mx+qnorm(1-a/2)*sigma/sqrt(n),4),"\n")
+ }
s.e. 1-a= 0.95 LB= -1.5514 UB= 2.1674
s.e. 1-a= 0.9 LB= -1.2524 UB= 1.8684
s.e. 1-a= 0.8 LB= -0.9078 UB= 1.5238
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ ένα δείγμα από κανονική κατανομή

Δ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά άγνωστη

$$\left[\bar{X} - t_{n-1,a/2}\frac{S}{\sqrt{n}}\ ,\ \ \bar{X} + t_{n-1,a/2}\frac{S}{\sqrt{n}}\right]$$

```
# METHOD A

c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))

n<-length(x)
Mx<-mean(x)
S<-sd(x)
```

```
# METHOD B    1-a=0.95
t.test(x)
```

Α.Φ.Ε. και Κ.Φ.Ε. για την μέση τιμή με σ.ε. $100(1-a)\%$-Διασπορά άγνωστη

$$\bar{X} - t_{n-1,a}\frac{S}{\sqrt{n}} \rightsquigarrow \text{Κ.Φ.Ε.} \qquad \bar{X} + t_{n-1,a}\frac{S}{\sqrt{n}} \rightsquigarrow \text{Α.Φ.Ε.}$$

```
t.test(x,alternative="greater")

t.test(x,alternative="less")
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
- ✓ δεν έχω τις παρατηρήσεις, μόνον τις δειγματικές παραμέτρους

Άσκηση 1

X : μετράει την επιφάνεια που καλύφθηκε από το χρώμα των κουτιών,

$$X_1, \ldots, X_{12} \text{ τυχαίο δείγμα } \sim \mathcal{N}(\mu, \sigma^2)$$

$$\left[\bar{X} - t_{n-1,a/2}\frac{S}{\sqrt{n}} \ , \ \bar{X} + t_{n-1,a/2}\frac{S}{\sqrt{n}}\right]$$

$$\bar{X} = 65 \ , \ \ s = 3 \ , \ \ n = 12 \ , \ \ 1 - a = 0.9 \ , \ \ t_{11,0.05} = 1.796$$

$$(63.44 \ , \ \ 66.56)$$

```
> n<-12
> Mx<-65
> S<-3
> cat("n=",n,"Mx=",Mx,"S^2=",S^2,"\n")
n= 12 Mx= 65 S^2= 9
> for (a in c(0.05,0.1,0.2)){
+ cat("s.e. 1-a=",1-a,"  t",n-1,"(",a/2,")=",round(qt(1-a/2,n-1),3),
+ "  [",round(Mx+qt(a/2,n-1)*S/sqrt(n),4),",",
+ round(Mx+qt(1-a/2,n-1)*S/sqrt(n),4),"]","\n")
+ }
s.e. 1-a= 0.95   t 11 ( 0.025 )= 2.201   [ 63.0939 , 66.9061 ]
s.e. 1-a= 0.9   t 11 ( 0.05 )= 1.796   [ 63.4447 , 66.5553 ]
s.e. 1-a= 0.8   t 11 ( 0.1 )= 1.363   [ 63.8192 , 66.1808 ]
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
- ✓ έχω τις παρατηρήσεις

The data are weight changes of humans, tabulated after administration of a drug proposed to result in weight loss. Each weight change (in kg) is the weight after minus the weight before drug administration.

0.2 -0.5 -1.3 -1.6 -0.7 0.4 -0.1 0.0 -0.6 -1.1 -1.2 -0.8

mean of x: -0.6083333

95 percent confidence interval: [-1.0105948, -0.2060719]

90 percent confidence interval: [-0.9365569, -0.2801098]

95 percent confidence interval: [-0.9365569, Inf)

95 percent confidence interval: (–Inf, -0.2801098]

- ✓ ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
  - ✓ έχω τις παρατηρήσεις (συνέχεια…)

```
> x<-scan()
1: 0.2 -0.5 -1.3 -1.6 -0.7 0.4 -0.1 0.0 -0.6 -1.1 -1.2 -0.8
13:
Read 12 items
> n<-length(x)
> Mx<-mean(x)
> S<-sd(x)
> cat("n=",n,"Mx=",Mx,"S^2=",var(x),"\n")
n= 12 Mx= -0.6083333 S^2= 0.4008333
> # 95% Conf Inter for m
> # METHOD A
> a<-0.05
> c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))
[1] -1.0105948 -0.2060719
> # METHOD B   1-a=0.95
> t.test(x)

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.006729
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -1.0105948 -0.2060719
sample estimates:
 mean of x
-0.6083333
```

- ένα δείγμα από κανονική κατανομή, ΔΕ για τη μέση τιμή, άγνωστη διασπορά
  - έχω τις παρατηρήσεις (συνέχεια…)

```
> a<-0.1
> # METHOD A
> c(Mx+qt(a/2,n-1)*S/sqrt(n),Mx+qt(1-a/2,n-1)*S/sqrt(n))
[1] -0.9365569 -0.2801098
> # METHOD B
> t.test(x,conf.level=1-a)

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.006729
alternative hypothesis: true mean is not equal to 0
90 percent confidence interval:
 -0.9365569 -0.2801098
sample estimates:
 mean of x
-0.6083333
```

- ✓ ένα δείγμα από κανονική κατανομή, ΕΥ για τη μέση τιμή, άγνωστη διασπορά
  - ✓ έχω τις παρατηρήσεις (συνέχεια…)

Έλεγχοι Υπόθεσης (ένα δείγμα)

- για μέση τιμή δείγματος από κανονική κατανομή

$H_0: \mu=\mu_0$ $H_0: \mu\leq\mu_0$ $H_0: \mu\geq\mu_0$
$H_1: \mu\neq\mu_0$ $H_1: \mu>\mu_0$ $H_1: \mu<\mu_0$

```
> t.test(x)

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.006729
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -1.0105948 -0.2060719
sample estimates:
 mean of x
-0.6083333
```

$\mu_0=0$

δεν ανήκει στο δ.ε. σ.ε. 95%

οπότε p-value<5%

✓ **έχω τις παρατηρήσεις δείγματος από κανονική κατανομή, ΕΥ για τη μέση τιμή, άγνωστη διασπορά (συνέχεια…)**

Ε.Υ. για τη μέση τιμή με ε.σ. a – Διασπορά άγνωστη ($t-test$)

$$t = \sqrt{n}\,\frac{\bar{x}-\mu_0}{s}$$

			Απόρριψη της H_0
$H_0 : \mu = \mu_0$	$vs.$	$H_1 : \mu \neq \mu_0$	$\lvert t\rvert > t_{n-1,a/2}$
$H_0 : \mu \leqslant \mu_0$	$vs.$	$H_1 : \mu > \mu_0$	$t > t_{n-1,a}$
$H_0 : \mu \geqslant \mu_0$	$vs.$	$H_1 : \mu < \mu_0$	$t < -t_{n-1,a}$

```
> t.test(x,alternative="greater")

        One Sample t-test

data:  x
t = -3.3285, df = 11, p-value = 0.9966
alternative hypothesis: true mean is greater than 0
95 percent confidence interval:
 -0.9365569        Inf
sample estimates:
 mean of x
-0.6083333
```

```
> t.test(x,alternative="less")

        One Sample t-test

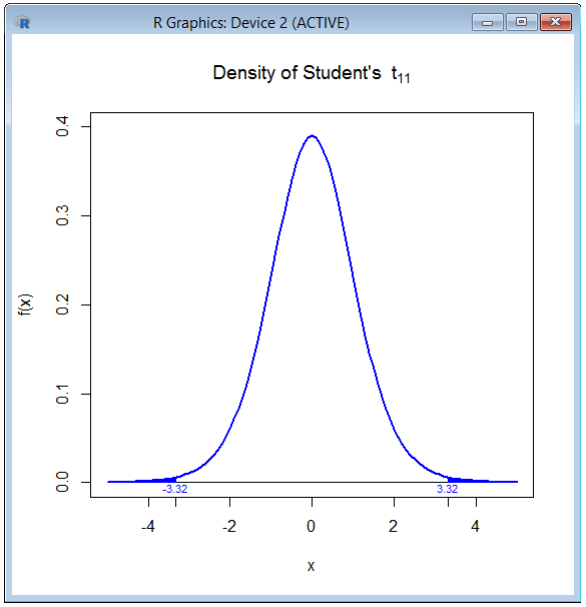
data:  x
t = -3.3285, df = 11, p-value = 0.003364
alternative hypothesis: true mean is less than 0
95 percent confidence interval:
       -Inf -0.2801098
sample estimates:
 mean of x
-0.6083333
```

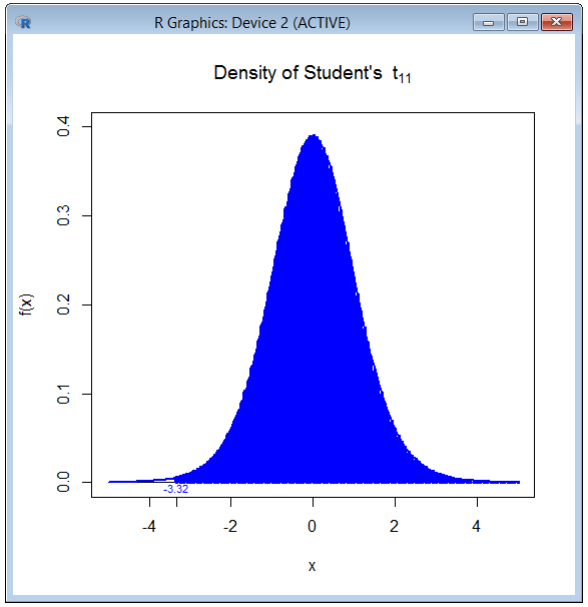
```
90 percent confidence interval:
 -0.9365569 -0.2801098
```

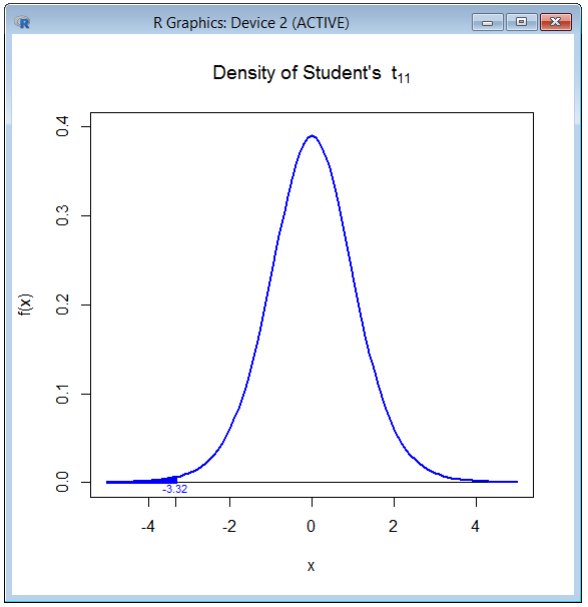
✓ **έχω τις παρατηρήσεις δείγματος από κανονική κατανομή, ΕΥ για τη μέση τιμή, άγνωστη διασπορά (συνέχεια…)**

$$t = \sqrt{n}\,\frac{\bar{x} - \mu_0}{s}$$

```
> m0<-0
> t<-(Mx-m0)/S*sqrt(n)
> pvalue.ne<-2*min(pt(t,n-1),1-pt(t,n-1))
> pvalue.g<-1-pt(t,n-1)
> pvalue.l<-pt(t,n-1)
> round(c(t,n-1,pvalue.ne,pvalue.g,pvalue.l),4)
[1] -3.3285 11.0000  0.0067  0.9966  0.0034
```

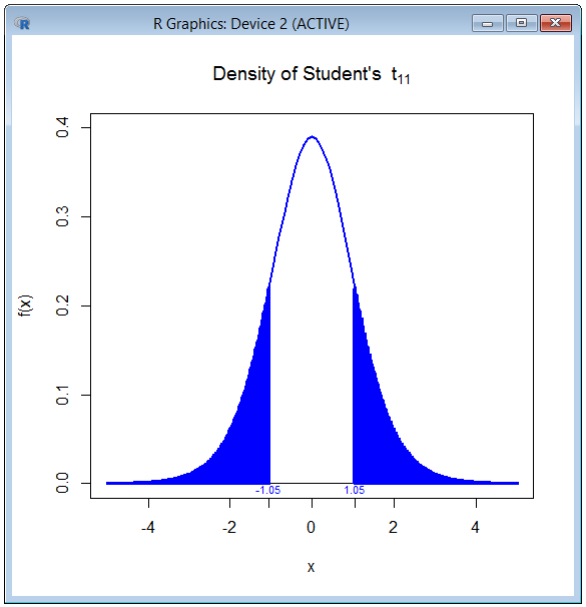


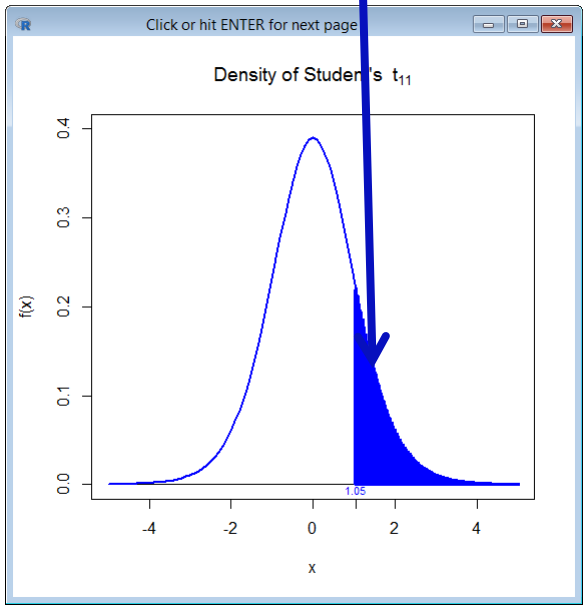


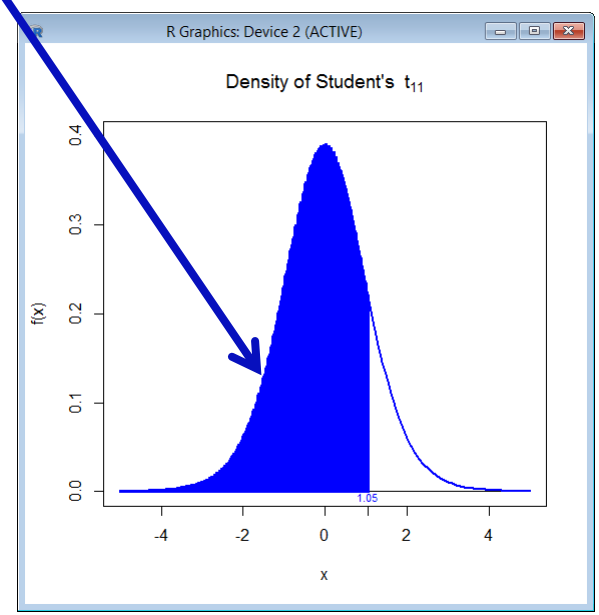


✓ έχω τις παρατηρήσεις δείγματος από κανονική κατανομή, ΕΥ για τη μέση τιμή, άγνωστη διασπορά (συνέχεια…)

```
> m0<--0.8
> t<-(Mx-m0)/S*sqrt(n)
> pvalue.ne<-2*min(pt(t,n-1),1-pt(t,n-1))
> pvalue.g<-1-pt(t,n-1)
> pvalue.l<-pt(t,n-1)
> round(c(t,n-1,pvalue.ne,pvalue.g,pvalue.l),4)
[1]  1.0487 11.0000  0.3168  0.1584  0.8416
```







✓ **έχω τις παρατηρήσεις δείγματος από κανονική κατανομή, ΕΥ για τη μέση τιμή, άγνωστη διασπορά (συνέχεια…)**

```
> t.test(x,mu=m0)

        One Sample t-test

data:  x
t = 1.0487, df = 11, p-value = 0.3168
alternative hypothesis: true mean is not equal to -0.8
95 percent confidence interval:
 -1.0105948 -0.2060719
sample estimates:
 mean of x
-0.6083333
```

μ_0=-0.8

ανήκει στο δ.ε. σ.ε. 90%

οπότε p-value>10%

```
> t.test(x,mu=m0,conf.level=1-0.3168)

        One Sample t-test

data:  x
t = 1.0487, df = 11, p-value = 0.3168
alternative hypothesis: true mean is not equal to -0.8
68.32 percent confidence interval:
 -0.8000030 -0.4166636
sample estimates:
 mean of x
-0.6083333
```

το μ_0=-0.8

ανήκει στα δ.ε. σ.ε. 1-α> 1-p-value=68.32%

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ **ένα δείγμα από κανονική κατανομή**

Δ.Ε. για την διασπορά με σ.ε. $100(1-a)\%$-μέση τιμή άγνωστη

$$\left[\frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\chi^2_{n-1,a/2}} , \frac{\sum_{i=1}^{n}(X_i-\bar{X})^2}{\chi^2_{n-1,1-a/2}} \right]$$

```
> x<-scan()
1: -1.26 -2.05  3.77  3.88 -2.24  0.13 -2.47  0.18  4.90 -1.76
11:
Read 10 items
> n<-length(x)
> S2<-var(x)
> a<-0.05
> c(S2*(n-1)/qchisq(1-a/2,n-1),S2*(n-1)/qchisq(a/2,n-1))
[1]  3.805133 26.805081
> cat("n=",n,"Mx=",Mx,"S^2=",S2,"\n")
n= 10 Mx= 65 S^2= 8.042684
> for (a in c(0.05,0.1,0.2)){
+ cat("s.e. 1-a=",1-a,"  X^2",n-1,"(",1-a/2,")=",round(qchisq(a/2,n-1),3),
+ "  X^2",n-1,"(",a/2,")=",round(qchisq(1-a/2,n-1),3),
+ "  [",round(S2*(n-1)/qchisq(1-a/2,n-1),4),",",
+ round(S2*(n-1)/qchisq(a/2,n-1),4),"]","\n")
+ }
s.e. 1-a= 0.95   X^2 9 ( 0.975 )= 2.7   X^2 9 ( 0.025 )= 19.023   [ 3.8051 , 26.8051 ]
s.e. 1-a= 0.9   X^2 9 ( 0.95 )= 3.325   X^2 9 ( 0.05 )= 16.919   [ 4.2783 , 21.7689 ]
s.e. 1-a= 0.8   X^2 9 ( 0.9 )= 4.168   X^2 9 ( 0.1 )= 14.684   [ 4.9296 , 17.366 ]
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ **για ποσοστό (ασυμπτωτικά)**

Άσκηση 2

X : μετράει το πλήθος των ατόμων που δήλωσαν προτίμηση στα τσιγάρα τύπου Α.

$$X_1, \ldots, X_{500} \text{ τυχαίο δείγμα } \sim \mathcal{B}(1, p)$$

$$\left[\bar{X} - z_{a/2}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \ , \ \bar{X} + z_{a/2}\sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right]$$

$$\bar{X} = \frac{311}{500} \ , \ n = 500 \ , \ 1 - a = 0.95 \ , \ z_{0.025} = 1.96$$

$$(0.58 \ , \ 0.66)$$

```
> # METHOD A
> a<-0.05
> n<-500
> p<-311/n
> c(p+qnorm(a/2)*sqrt(p*(1-p)/n),p+qnorm(1-a/2)*sqrt(p*(1-p)/n))
[1] 0.5794985 0.6645015

> # METHOD B
> prop.test(311,500); prop.test(311,500,correct = FALSE)

95 percent confidence interval:
 0.5777064 0.6643897

95 percent confidence interval:
 0.5787205 0.6634192

> # METHOD C
> binom.test(311,500); binom.test(311,500,conf.level= 0.90)

        Exact binomial test

95 percent confidence interval:
 0.5778777 0.6646706
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

- ✓ **για ποσοστό (ασυμπτωτικά)**

Εφαρμογή: Α.Ε.Υ. για το ποσοστό με ε.σ. a ($z-test$)

$$z = \sqrt{n}\,\frac{\bar{x}-p_0}{\sqrt{\bar{x}(1-\bar{x})}}$$

			Απόρριψη της H_0
$H_0: p = p_0$	$vs.$	$H_1: p \neq p_0$	$\lvert z\rvert > z_{a/2}$
$H_0: p \leqslant p_0$	$vs.$	$H_1: p > p_0$	$z > z_a$
$H_0: p \geqslant p_0$	$vs.$	$H_1: p < p_0$	$z < -z_a$

```
# METHOD A
#z1<-(p-p0)/sqrt(p*(1-p)/n)
z<-(p-p0)/sqrt(p0*(1-p0)/n)
c(abs(z)<qnorm(1-a/2),z<qnorm(1-a),z>qnorm(a))
pvalue.ne<-2*min(pnorm(z),1-pnorm(z))
pvalue.g<-1-pnorm(z); pvalue.l<-pnorm(z)
cat(p,z,"z a/2=",qnorm(1-a/2),"z a=",qnorm(1-a),"-z a=",qnorm(a)
,pvalue.ne,pvalue.g,pvalue.l,"\n")

# METHOD B
prop.test(x,n,p0); prop.test(x,n,p0,correct = FALSE)

# METHOD C
binom.test(x,n,p=p0,conf.level= 0.80)
```

Έλεγχοι Υποθέσεων ✓ για ποσοστό (ασυμπτωτικά)

Άσκηση 8

X : μετράει αν χρησιμοποιούνται οι τηλεοράσεις του εργοστασίου.

$$X_1, \ldots, X_{700} \text{ τυχαίο δείγμα } \sim \mathcal{B}(1, p)$$

$$H_0 : p = 0.6 \quad vs. \quad H_1 : p \neq 0.6$$

$$\bar{x} = \frac{400}{700} = 0.57\,, \quad a = 0.05\,, \quad z_{0.025} = 1.96$$

$$z = \frac{\bar{x} - p_0}{\sqrt{\frac{\bar{x}(1-\bar{x})}{n}}} = -1.6,\ |z| < z_{0.025} \Rightarrow \text{δεν απορρίπτω την } H_0, \text{ δηλ.}$$

ισχύει ο ισχυρισμός.

```
> a<-0.05
> n<-700
> x<-400
> p<-x/n
> p0<-0.6
>
> # METHOD A
> #z1<-(p-p0)/sqrt(p*(1-p)/n)
> z<-(p-p0)/sqrt(p0*(1-p0)/n)
> c(abs(z)<qnorm(1-a/2),z<qnorm(1-a),z>qnorm(a))
[1] TRUE TRUE TRUE
>
> pvalue.ne<-2*min(pnorm(z),1-pnorm(z))
> pvalue.g<-1-pnorm(z); pvalue.l<-pnorm(z)
> cat(p,z,"z a/2=",qnorm(1-a/2),"z a=",qnorm(1-a),"-z a=",qnorm(a),
0.5714286 -1.543033 z a/2= 1.959964 z a= 1.644854 -z a= -1.644854
> cat(pvalue.ne,pvalue.g,pvalue.l,"\n")
0.1228226 0.9385887 0.06141132
```

Έλεγχοι Υποθέσεων ✓ για ποσοστό (ασυμπτωτικά)

```
> # METHOD C
> binom.test(x,n,p=p0,conf.level= 0.80)

        Exact binomial test

data:  x and n
number of successes = 400, number of trials = 700, p-value = 0.123
alternative hypothesis: true probability of success is not equal to 0.6
80 percent confidence interval:
 0.5466169 0.5959392
sample estimates:
probability of success
             0.5714286
```

```
> binom.test(400,700,p=0.6,alternative="greater",conf.level= 0.90)

        Exact binomial test

data:  400 and 700
number of successes = 400, number of trials = 700, p-value =
0.9427
alternative hypothesis: true probability of success is greater than 0.6
90 percent confidence interval:
 0.5466169 1.0000000
sample estimates:
probability of success
            0.5714286
```

```
> binom.test(400,700,p=0.6,alternative="less",conf.level= 0.90)

        Exact binomial test

data:  400 and 700
number of successes = 400, number of trials = 700, p-value =
0.06662
alternative hypothesis: true probability of success is less than 0.6
90 percent confidence interval:
 0.0000000 0.5959392
sample estimates:
probability of success
            0.5714286
```

- ✓ **δύο ανεξάρτητα δείγματα από κανονική κατανομή, ίσες διασπορές**

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα $\sim \mathcal{N}(\mu_1, \sigma_1^2)$
$Y_1, Y_2, \ldots, Y_m$ τυχαίο δείγμα $\sim \mathcal{N}(\mu_2, \sigma_2^2)$

Δ.Ε. για το $\mu_1 - \mu_2$ με σ.ε. $100(1-\alpha)\%$-Διασπορές άγνωστες ($\sigma_1^2 = \sigma_2^2$)

$$\left[\bar{X} - \bar{Y} - t_{n+m-2,\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}}\ ,\ \bar{X} - \bar{Y} + t_{n+m-2,\alpha/2} S_p \sqrt{\frac{1}{n} + \frac{1}{m}}\right]$$

$$S_p^2 = \frac{(n-1)s_1^2 + (m-1)s_2^2}{n+m-2}$$

```
t.test(x,y,var.equal=T,conf.level= 1-a)
```

- ✓ **δύο ανεξάρτητα δείγματα από κανονική κατανομή, άνισες διασπορές**

$$\bar{x} - \bar{y} \pm t_{\nu;\, a/2} \sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}} \quad \text{και} \quad \nu = \frac{\left(\frac{s_1^2}{n} + \frac{s_2^2}{m}\right)^2}{\frac{\left(\frac{s_1^2}{n}\right)^2}{n-1} + \frac{\left(\frac{s_2^2}{m}\right)^2}{m-1}}$$

```
t.test(x,y,conf.level= 1-a)
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή

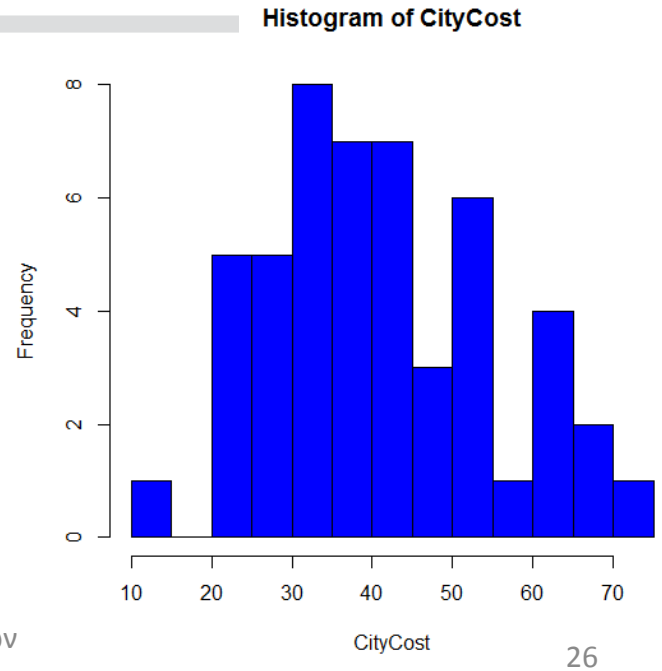
Data about the cost of a meal per person from a sample of 50 city restaurants

City Cost Data									
13	21	22	22	24	25	26	26	26	26
30	32	33	34	34	35	35	35	35	36
37	37	39	39	39	40	41	41	41	42
43	44	45	46	50	50	51	51	53	53
53	55	57	61	62	62	62	66	68	75

mean of x : 41.46

95 percent confidence interval: [37.51277 , 45.40723]

80 percent confidence interval: [38.90835, 44.01165]



Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή

Data about the cost of a meal per person from a sample of 40 suburban restaurants.

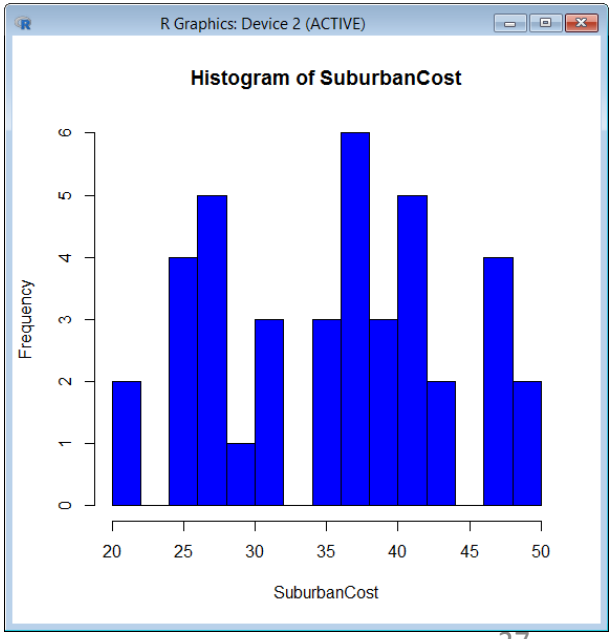
Suburban Cost Data									
21	22	25	25	26	26	27	27	28	28
28	29	31	32	32	35	35	36	37	37
37	38	38	38	39	40	40	41	41	41
42	42	43	44	47	47	47	48	50	50

Does a meal per person cost the same in both types of restaurants?

mean of y : 36

95 percent confidence interval: [33.41902, 38.58098]

80 percent confidence interval: [34.33654, 37.66346]



Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

- ✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή

```
> t.test(x,y,var.equal=T)

        Two Sample t-test

data:  x and y
t = 2.2048, df = 88, p-value = 0.03007
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
  0.5387032 10.3812968
sample estimates:
mean of x mean of y
    41.46     36.00

> t.test(x,y)

        Welch Two Sample t-test

data:  x and y
t = 2.331, df = 80.967, p-value = 0.02224
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
  0.7995432 10.1204568
sample estimates:
mean of x mean of y
    41.46     36.00
```

το 0
δεν ανήκει στο
δ.ε. σ.ε. 95%

οπότε
$H_0: \mu_1=\mu_2 \ (\mu_1-\mu_2=0)$
$H_1: \mu_1\neq\mu_2 \ (\mu_1-\mu_2\neq0)$
p-value<5%

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

- ✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή

Ε.Υ. για το $\mu_1 - \mu_2$ με ε.σ. a - Διασπορές άγνωστες ($\sigma_1^2 = \sigma_2^2$) ($t - test$)

$$t = \frac{\bar{x} - \bar{y} - \mu_0}{S_p\sqrt{\frac{1}{n} + \frac{1}{m}}}$$

			Απόρριψη της H_0
$H_0 : \mu_1 - \mu_2 = \mu_0$	vs.	$H_1 : \mu_1 - \mu_2 \neq \mu_0$	$\lvert t \rvert > t_{n+m-2,a/2}$
$H_0 : \mu_1 - \mu_2 \leqslant \mu_0$	vs.	$H_1 : \mu_1 - \mu_2 > \mu_0$	$t > t_{n+m-2,a}$
$H_0 : \mu_1 - \mu_2 \geqslant \mu_0$	vs.	$H_1 : \mu_1 - \mu_2 < \mu_0$	$t < -t_{n+m-2,a}$

```
> m0<-3
> t.test(x,y,mu=m0,var.equal=T)

        Two Sample t-test

data:  x and y
t = 0.99338, df = 88, p-value = 0.3232
alternative hypothesis: true difference in means is not equal to 3
95 percent confidence interval:
  0.5387032 10.3812968
sample estimates:
mean of x mean of y
    41.46     36.00
```

```
> t.test(x,y,mu=m0)

        Welch Two Sample t-test

data:  x and y
t = 1.0503, df = 80.967, p-value = 0.2967
alternative hypothesis: true difference in means
95 percent confidence interval:
  0.7995432 10.1204568
sample estimates:
mean of x mean of y
    41.46     36.00
```

το 3 ανήκει στο δ.ε. σ.ε. 95%

οπότε

H_0: $\mu_1=\mu_2+3$ ($\mu_1-\mu_2=3$)

H_1: $\mu_1\neq\mu_2+3$ ($\mu_1-\mu_2\neq3$)

p-value>5%

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για το πηλίκο των διασπορών

- ✓ **δύο ανεξάρτητα δείγματα από κανονική κατανομή**

$X_1, X_2, \ldots, X_n$ τυχαίο δείγμα $\sim \mathcal{N}(\mu_1, \sigma_1^2)$
$Y_1, Y_2, \ldots, Y_m$ τυχαίο δείγμα $\sim \mathcal{N}(\mu_2, \sigma_2^2)$

Δ.Ε. για το σ_1^2/σ_2^2 με σ.ε. $100(1-a)\%$-μέσες τιμές άγνωστες

$$\left[\frac{1}{F_{n-1,m-1,a/2}}\frac{S_1^2}{S_2^2}\,,\ \frac{1}{F_{n-1,m-1,1-a/2}}\frac{S_1^2}{S_2^2}\right]$$

```
var.test(x,y,conf.level= 1-a)
```

Ε.Υ. για το σ_1^2/σ_2^2 με ε.σ. a – Μέσες τιμές άγνωστες ($F-test$)

$$F = \frac{s_1^2}{s_2^2}$$

	Απόρριψη της H_0
$H_0: \frac{\sigma_1^2}{\sigma_2^2} = \delta_0$ vs. $H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq \delta_0$	$F < F_{n-1,m-1,1-a/2}\ \delta_0$ ή $F > F_{n-1,m-1,a/2}\ \delta_0$
$H_0: \frac{\sigma_1^2}{\sigma_2^2} \leqslant \delta_0$ vs. $H_1: \frac{\sigma_1^2}{\sigma_2^2} > \delta_0$	$F > F_{n-1,m-1,a}\ \delta_0$
$H_0: \frac{\sigma_1^2}{\sigma_2^2} \geqslant \delta_0$ vs. $H_1: \frac{\sigma_1^2}{\sigma_2^2} < \delta_0$	$F < F_{n-1,m-1,1-a}\ \delta_0$

```
var.test(x,y,ratio=d0,conf.level= 1-a)
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για το πηλίκο των διασπορών

- ✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή

```
> x<-CityCost
> y<-SuburbanCost
> a<-0.01
> var.test(x,y,conf.level= 1-a)

        F test to compare two variances

data:  x and y
F = 2.962, num df = 49, denom df = 39, p-value = 0.0006743
alternative hypothesis: true ratio of variances is not equal to 1
99 percent confidence interval:
 1.315084 6.467398
sample estimates:
ratio of variances
          2.961951
```

το 1
δεν ανήκει στο
δ.ε. σ.ε. 99%

οπότε
$H_0: \sigma^2_1=\sigma^2_2 \ (\sigma^2_1/\sigma^2_2=1)$
$H_1: \sigma^2_1\neq\sigma^2_2 \ (\sigma^2_1/\sigma^2_2\neq1)$
p-value<0.1%

```
> a<-0.2
> d0<-2
> var.test(x,y,ratio=d0,conf.level= 1-a)

        F test to compare two variances

data:  x and y
F = 1.481, num df = 49, denom df = 39, p-value = 0.2071
alternative hypothesis: true ratio of variances is not equal to 2
80 percent confidence interval:
 1.987631 4.357250
sample estimates:
ratio of variances
          2.961951
```

το 2
ανήκει στο
δ.ε. σ.ε. 80%

οπότε
$H_0: \sigma^2_1=2\sigma^2_2 \ (\sigma^2_1/\sigma^2_2=2)$
$H_1: \sigma^2_1\neq2\sigma^2_2 \ (\sigma^2_1/\sigma^2_2\neq2)$
p-value>20%

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

- ✓ **δύο ανεξάρτητα δείγματα από κανονική κατανομή (ζευγαρωτές παρατηρήσεις)**

$\bar{z} \pm \frac{s_z}{\sqrt{n}} t_{n-1;\, a/2}$ όπου $\bar{z}$ η μέση τιμή των $x_i - y_i$

και s_z^2 η διασπορά των $x_i - y_i$

```
t.test(x,y,paired=T)
```

H_0	H_1	
$\mu_1 - \mu_2 = \delta$	$\mu_1 - \mu_2 \neq \delta$	$R = \left\{ \left\| \frac{\bar{z}\sqrt{n}}{s_z} \right\| > t_{n-1;\, a/2} \right\}$ όπου $\bar{z}$ και s_z η μέση τιμή και η τυπική απόκλιση των $x_i - y_i$
$\mu_1 - \mu_2 = \delta$	$\mu_1 - \mu_2 > \delta$	$R = \left\{ \frac{\bar{z}\sqrt{n}}{s_z} > t_{n-1;\, a} \right\}$
$\mu_1 - \mu_2 = \delta$	$\mu_1 - \mu_2 < \delta$	$R = \left\{ \frac{\bar{z}\sqrt{n}}{s_z} < -t_{n-1;\, a} \right\}$

```
t.test(x,y,mu=d,paired=T)
t.test(x,y,mu=d,alternative="greater",paired=T)
t.test(x,y,mu=d,alternative="less",paired=T)
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

- ✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή (ζευγαρωτές παρατηρήσεις)

Bacterial Densities. The data below are the natural logarithms of bacterial counts as measured by two analysts on identical aliquots of river water. Are the analysts getting the same result?

Analyst A	1.60	1.74	1.72	1.85	1.76	1.72	1.78
Analyst B	1.72	1.75	1.55	1.67	2.05	1.51	1.70

```
> AnalystA<-c(1.60, 1.74, 1.72, 1.85, 1.76, 1.72, 1.78)
> AnalystB<-c(1.72, 1.75, 1.55, 1.67, 2.05, 1.51, 1.70)
> x<-AnalystA
> y<-AnalystB
>
> t.test(x,y,paired=T)

        Paired t-test

data:  x and y
t = 0.45153, df = 6, p-value = 0.6675
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.1388895  0.2017466
sample estimates:
mean of the differences
             0.03142857
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων, για τη διαφορά των μέσων τιμών

- ✓ δύο ανεξάρτητα δείγματα από κανονική κατανομή (ζευγαρωτές παρατηρήσεις)

```
> d<-0
> t.test(x,y,mu=d,alternative="greater",paired=T)

        Paired t-test

data:  x and y
t = 0.45153, df = 6, p-value = 0.3337
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 -0.1038271        Inf
sample estimates:
mean of the differences
             0.03142857

> t.test(x,y,mu=d,alternative="less",paired=T)

        Paired t-test

data:  x and y
t = 0.45153, df = 6, p-value = 0.6663
alternative hypothesis: true difference in means is less than 0
95 percent confidence interval:
      -Inf 0.1666842
sample estimates:
mean of the differences
             0.03142857
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

✓ δύο ανεξάρτητα δείγματα, διαφορά δύο ποσοστών (ασυμπτωτικά)

Άσκηση 4

X : μετράει αν είναι ελαττωματική η συσκευή από τον Α.
Y : μετράει αν είναι ελαττωματική η συσκευή από τον Β.

$$X_1, \ldots, X_{120} \text{ τυχαίο δείγμα } \sim \mathcal{B}(1, p_1)$$

$$Y_1, \ldots, Y_{80} \text{ τυχαίο δείγμα } \sim \mathcal{B}(1, p_2)$$

$$H_0 : p_1 \leqslant p_2 \quad vs. \quad H_1 : p_1 > p_2$$

$$\bar{x} = \frac{6}{120}\,, \quad \bar{y} = \frac{5}{80}\,, \quad a = 0.01\,, \quad z_{0.01} = 2.33$$

```
> A<- c(6,120-6)
> B<- c( 5,80-5)
> rbind(A,B)
  [,1] [,2]
A    6  114
B    5   75
> prop.test(rbind(A,B),alternative="greater")

        2-sample test for equality of proportions with continuity
        correction

data:  rbind(A, B)
X-squared = 0.0040083, df = 1, p-value = 0.5252
alternative hypothesis: greater
95 percent confidence interval:
 -0.07816649  1.00000000
sample estimates:
prop 1 prop 2
0.0500 0.0625

Warning message:
In prop.test(rbind(A, B), alternative = "greater") :
  Chi-squared approximation may be incorrect
```

Διαστήματα εμπιστοσύνης-Έλεγχοι Υποθέσεων

✓ δύο ανεξάρτητα δείγματα, διαφορά πολλών ποσοστών (ασυμπτωτικά)

H_0 : the four populations from which the patients were drawn have the same true proportion of smokers.

H_1 : this proportion is different in at least one of the populations.

	I	II	III	IV
smokers	83	90	129	70
Non smokers	3	3	7	12

```
> smokers  <- c( 83, 90, 129, 70 )
> patients <- c( 86, 93, 136, 82 )
> prop.test(smokers, patients)

        4-sample test for equality of proportions without continuity
        correction

data:  smokers out of patients
X-squared = 12.6, df = 3, p-value = 0.005585
alternative hypothesis: two.sided
sample estimates:
   prop 1    prop 2    prop 3    prop 4
0.9651163 0.9677419 0.9485294 0.8536585
```