χ^2 ΈΛΕΓΧΟΣ ΚΑΛΗΣ ΠΡΟΣΑΡΜΟΓΗΣ

Στατιστική Συμπερασματολογία ΙΙ, Κ. Πετρόπουλος

Πολυωνυμική Κατανομή

Ένα τυχαίο διάνυσμα $\underset{\sim}{X} = (X_1, X_2, \ldots, X_k)$ ακολουθεί την πολυωνυμική κατανομή, εάν η π.π. του τ.δ. είναι

$$f(\underset{\sim}{x}) = P(\underset{\sim}{X} = \underset{\sim}{x}) = \frac{n!}{x_1! x_2! \ldots x_k!} p_1^{x_1} p_2^{x_2} \ldots p_k^{x_k}$$

όπου $\underset{\sim}{x} = (x_1, x_2, \ldots, x_k)$, $x_1 + x_2 + \ldots + x_k = n$ και $0 < p_i < 1$, $i = 1, 2, \ldots, k$ είναι πιθανότητες τ.ω. $p_1 + p_2 + \ldots + p_k = 1$.
Συμβολισμός: $\underset{\sim}{X} \sim \Pi(n; p_1, p_2, \ldots, p_k)$.

Περιγραφή Τυχαίου Πειράματος

Θεωρούμε ότι έχουμε ένα τυχαίο πείραμα με k δυνατά αποτελέσματα, έστω $A_1, A_2, \ldots, A_k$, με πιθανότητα εμφάνισης $P(A_i) = p_i$, $i = 1, 2, \ldots, k$.
Αν X_i, $i = 1, 2, \ldots, k$ είναι η τ.μ. η οποία μετράει το πλήθος εμφάνισης του γεγονότος A_i, τότε το τ.δ. $\underset{\sim}{X} = (X_1, X_2, \ldots, X_k) \sim \Pi(n; p_1, p_2, \ldots, p_k)$.

Παρατήρηση: κάθε $X_i \sim B(n, p_i)$, $i = 1, \ldots, k$

ΓΕΝΙΚΕΥΣΗ ΩΣ ΠΡΟΣ ΤΗΝ ΚΑΤΑΝΟΜΗ

Θεωρούμε τ.δ. $\underset{\sim}{X} = (X_1, X_2, \ldots, X_k) \sim \Pi(n; p_1, p_2, \ldots, p_k)$.

$$H_0 : p_i = p_{i0} \; \forall \; i = 1, \ldots, k \;\; vs. \;\; H_1 : p_i \neq p_{i0} \;\; \text{για κάποιο} \;\; 1 \leqslant i \leqslant k.$$

$\Pi_i = x_i$: οι παρατηρηθείσες τιμές $\qquad A_i = np_{i0}$: οι αναμενόμενες τιμές.
Ο έλεγχος βασίζεται στη σ.σ.

$$X^2 = \sum_{i=1}^{k} \frac{(x_i - np_{i0})^2}{np_{i0}}$$

η οποία, υπό την H_0, έχει ασυμπτωτική κατανομή $\mathcal{X}^2_{k-1}$.
«Μεγάλη» τιμή του X^2 είναι ένδειξη κατά της H_0. Άρα ο έλεγχος για το πρόβλημά μας είναι της μορφής,

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > c \\ 0 & , \quad X^2 \leqslant c \end{cases}$$

όπου c είναι σταθερά η οποία υπολογίζεται από το μέγεθος του ελέγχου, δηλαδή $a = E_{H_0}\phi(\underset{\sim}{x}) = P_{H_0}(X^2 > c) \Rightarrow c = \mathcal{X}^2_{k-1,a}$.
Οπότε, ο έλεγχος είναι

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{k-1,a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{k-1,a} \end{cases}$$

ΓΕΝΙΚΕΥΣΗ ΩΣ ΠΡΟΣ ΤΟ ΠΡΟΒΛΗΜΑ Ε.Υ.

Θεωρούμε τ.δ. $\underset{\sim}{X} = (X_1, X_2, \ldots, X_k) \sim \Pi(n; p_1, p_2, \ldots, p_k)$.

$$H_0 : (p_1, \ldots, p_k) \in \Theta_0 \;\; vs. \;\; H_1 : (p_1, \ldots, p_k) \notin \Theta_0$$

Π_i : οι παρατηρηθείσες τιμές $\qquad$ A_i : οι αναμενόμενες τιμές.
Ο έλεγχος βασίζεται στη σ.σ.

$$X^2 = \sum_{i=1}^{k} \frac{(\Pi_i - A_i)^2}{A_i} \sim \mathcal{X}^2_r$$

$r = k - 1 -$(πλήθος ανεξάρτητων εκτιμώμενων παραμέτρων για τον υπολογισμό των A_i, υπό την H_0).

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{r,a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{r,a} \end{cases}$$

Εφαρμογές $\mathcal{X}^2$ Ελέγχου Καλής Προσαρμογής

(A) Προσαρμογή σε Θεωρητικό μοντέλο

$H_0 : p_i = p_{i0}, \forall\ i = 1, \ldots, k$, κατά $H_1 : p_i \neq p_{i0}$, για κάποιο $1 \leqslant i \leqslant k$.

Αποτελέσματα	Παρατηρηθείσες Συχνότητες	Αναμενόμενες Συχνότητες
A_1	f_1	np_{10}
A_2	f_2	np_{20}
$\vdots$	$\vdots$	$\vdots$
A_k	f_k	np_{k0}

$n = \sum_{i=1}^{k} f_i$.

$$X^2 = \sum_{i=1}^{k} \frac{(f_i - np_{i0})^2}{np_{i0}}$$

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{r,a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{r,a} \end{cases}$$

(Α) Προσαρμογή σε Θεωρητικό μοντέλο

Παράδειγμα 1

Η ρίψη ζαριού 24 φορές έφερε τα εξής αποτελέσματα.

1	2	3	4	5	6
7	4	3	5	2	3

Τα δεδομένα αυτά δηλώνουν ότι το ζάρι είναι αμερόληπτο;

Παράδειγμα 2

109 απόγονοι μιας ορισμένης διασταύρωσης ταξινομούνται σε 3 ομάδες με βάση ένα ορισμένο χαρακτηριστικό.

1	2	3
10	53	46

Σύμφωνα με έναν νόμο γενετικής οι ομάδες αυτές εμφανίζονται με πιθανότητες p^2, $2p(1-p)$, $(1-p)^2$, με $p \in (0,1)$ άγνωστο. Να ελεγχθεί κατά πόσο τα πειραματικά δεδομένα συμφωνούν με το θεωρητικό πρότυπο.

Εφαρμογές $\mathcal{X}^2$ Ελέγχου Καλής Προσαρμογής

(Β) Έλεγχος Ανεξαρτησίας σε πίνακες συνάφειας

Θεωρούμε δύο χαρακτηριστικά Α και Β.
Έστω ότι το Α έχει k κατηγορίες $A_1, \ldots, A_k$, και το Β, s κατηγορίες $B_1, \ldots, B_s$.
Αν X_{ij} μετράει το πλήθος των ατόμων που ανήκουν στην κατηγορία A_i και B_j,
τότε $\underset{\sim}{X} = (X_{ij} : i = 1, \ldots, k, j = 1, \ldots, s) \sim \Pi(n; p_{ij}; i = 1, \ldots, k, j = 1, \ldots, s)$

όπου $p_{ij} = P(A_i \cap B_j)$, ακόμη θεωρούμε $p_i = P(A_i)$ και $q_j = P(B_j)$.

$$A, B \text{ είναι ανεξάρτητα χαρακτηριστικά } \Leftrightarrow p_{ij} = p_i q_j \ , \quad \forall\, i, j.$$

$$H_0 : p_{ij} = p_i q_j \ , \quad \forall\, i, j \ \ vs. \ \ H_1 : p_{ij} \neq p_i q_j \ , \quad \text{για κάποιο } (i, j)$$

x_{ij} : οι παρατηρηθείσες τιμές, A_{ij} : οι αναμενόμενες τιμές, υπό την H_0.
$A_{ij} = n\hat{p}_{ij} = n\hat{p}_i\hat{q}_j$, $\hat{p}_i = \dfrac{x_{i\cdot}}{n}$, $\hat{q}_j = \dfrac{x_{\cdot j}}{n}$

$$X^2 = \sum_{j=1}^{s} \sum_{i=1}^{k} \frac{\left(x_{ij} - \frac{x_{i\cdot} x_{\cdot j}}{n}\right)^2}{\frac{x_{i\cdot} x_{\cdot j}}{n}}$$

$r = k - 1 -$(πλήθος ανεξάρτητων εκτιμώμενων παραμέτρων υπό την H_0)
$= ks - 1 - (k - 1 + s - 1) = (k - 1)(s - 1)$.

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{(k-1)(s-1),a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{(k-1)(s-1),a} \end{cases}$$

(Β) Έλεγχος Ανεξαρτησίας σε πίνακες συνάφειας

Παράδειγμα 3

Στον παρακάτω πίνακα δίνεται ο αριθμός των φοιτητών ανά σχολή.

Φύλο/Σχολή	Θετ. Επιστ.	Πολυτεχ.	Φιλοσοφ.	Παιδαγ.	Ιατρική
Άνδρας	21	16	145	2	6
Γυναίκα	14	4	175	13	4

Να γίνει έλεγχος κατά πόσο η επιλογή σχολής είναι ανεξάρτητη από το φύλο.

Θεωρητικός τύπος για Πίνακα 2×2.

A/B	B_1	B_2
A_1	a	b
A_2	c	d

$$X^2 = \frac{\left(a-\frac{(a+c)(a+b)}{n}\right)^2}{\frac{(a+c)(a+b)}{n}} + \frac{\left(b-\frac{(a+b)(b+d)}{n}\right)^2}{\frac{(a+b)(b+d)}{n}} + \frac{\left(c-\frac{(a+c)(c+d)}{n}\right)^2}{\frac{(a+c)(c+d)}{n}} + \frac{\left(d-\frac{(b+d)(c+d)}{n}\right)^2}{\frac{(b+d)(c+d)}{n}}$$

$$= \frac{n(ad-bc)^2}{(a+b)(c+d)(a+c)(b+d)}.$$

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{1,a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{1,a} \end{cases}$$

Εφαρμογές $\mathcal{X}^2$ Ελέγχου Καλής Προσαρμογής

Διόρθωση Yates

Χρησιμοποιείται σε περιπτώσεις, όπου η αναμενόμενη τιμή κάποιου κελιού είναι «πολύ μικρή» (< 5).

(B1) Κάνω τον έλεγχο κανονικά, αν αποδεχτώ την H_0, σταματάω.

(B2) Αν απορρίψω την H_0, κάνω τη διόρθωση Yates, $X^2 = \sum_{j=1}^{s} \sum_{i=1}^{k} \frac{(|X_{ij} - A_{ij}| - 0.5)^2}{A_{ij}}$.

(B3) Αν συνεχίζω να απορρίπτω την H_0, σταματάω

(B4) Αν αποδεχτώ την H_0, πρέπει να ακολουθήσω άλλη διαδικασία για τον έλεγχο ανεξαρτησίας (π.χ. ΑΕΛΠ).

Παράδειγμα 4

60 πιλότοι, υποψήφιοι για κάποιες θέσεις σε μια αεροπορική εταιρεία, υποβάλλονται σε ένα ψυχολογικό τεστ σύμφωνα με το οποίο ταξινομούνται ως εσωστρεφείς ή εξωστρεφείς και σε ένα τεστ δεξιότητας στο οποίο βαθμολογούνται ως επιτυχόντες ή αποτυγχόντες. Από τους 36 επιτυχόντες, μόνο οι 3 θεωρήθηκαν εσωστρεφείς, ενώ 17 αποτυχόντες θεωρήθηκαν εξωστρεφείς. Θα ήταν εύλογο να υποθέσει κανείς ότι τα δεδομένα υπαινίσσονται ύπαρξη συσχέτισης μεταξύ του τύπου της προσωπικότητας και των δεξιοτήτων των πιλότων;

Εφαρμογές $\mathcal{X}^2$ Ελέγχου Καλής Προσαρμογής

(Γ) Έλεγχος Κατανομών (Ομαδοποιημένα Δεδομένα)

$\underset{\sim}{X} = (X_1, X_2, \ldots, X_n)$ τυχαίο δείγμα από κατανομή με π.π. f.

$$H_0 : X \sim f \quad vs. \quad H_1 : X \nsim f.$$

Αν τα δεδομένα ομαδοποιούνται σε τάξεις, ως εξής:

Τάξεις	Παρατηρηθείσες Συχνότητες	Αναμενόμενες Συχνότητες
$(a_0, a_1]$	f_1	np_1
$(a_1, a_2]$	f_2	np_2
$\vdots$	$\vdots$	$\vdots$
$(a_{k-1}, a_k]$	f_k	np_k

Y_i : μετράει το πλήθος των τιμών από το δείγμα $\underset{\sim}{X}$ στο διάστημα $I_i = (a_{i-1}, a_i]$, $i = 1, \ldots, k$

$$\underset{\sim}{Y} = (Y_1, Y_2, \ldots, Y_k) \sim \Pi(n; p_1, p_2, \ldots, p_k),$$

$$p_i = \int_{I_i} f(x)dx = P(X \in I_i).$$

$$X^2 = \sum_{i=1}^{k} \frac{(f_i - np_i)^2}{np_i}$$

$$\phi(\underset{\sim}{x}) = \begin{cases} 1 & , \quad X^2 > \mathcal{X}^2_{r,a} \\ 0 & , \quad X^2 \leqslant \mathcal{X}^2_{r,a} \end{cases}$$

Παράδειγμα 5

Δίνοντα τα διαστήματα, $A_1 = (-\infty, 0]$, $A_2 = (0, 1]$, $A_3 = (1, 2]$ και $A_4 = (2, +\infty)$. Τυχαίο δείγμα από μία κατανομή στο $\mathbb{R}$ έδωσε αντίστοιχα τις παρακάτω συχνότητες, $60, 96, 140, 704$. Να ελεγχθεί η υπόθεση ότι η κατανομή είναι η κανονική $\mathcal{N}(3, 4)$, με $a = 5\%$.

Παράδειγμα 6

Δίνονται οι εκπομπές αριθμών σωματιδίων a, από Βάριο – 133 σε διάστημα $1/10$ sec.

7	4	3	6	4	4	5	3	5	3
5	5	3	2	5	4	3	3	7	6
6	4	3	11	9	6	7	4	5	4
7	3	2	8	6	7	4	1	9	8
4	8	9	3	9	7	7	9	3	10

Ακολουθούν τα δεδομένα την κατανομή Poisson, με παράμετρο $\lambda = 5, 4$;

Παρατήρηση (Παράδειγμα 6)

Τα σημαντικά στοιχεία της μεθόδου που περιγράφηκε, είναι:

(α) επιλογή του k.

(β) επιλογή των A_i.

Γενικά δεν υπάρχει σαφής τρόπος επιλογής των k και A_i. Εμπειρικά έχουν διατυπωθεί τα εξής,

1. Η μεθοδολογία έχει επιτυχή αποτελέσματα όταν το k αυξάνει σαν συνάρτηση του n.
2. Μέριμνα πρέπει να λαμβάνεται, ώστε σε κάθε κατηγορία οι Αναμενόμενες τιμές να μην είναι πολύ μικρές. (> 5 ή > 10).